ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук		Н.В. Богословская
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №5

КЛАСТЕРИЗАЦИЯ

по курсу: БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №	4127		А. А. Костина
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2024

1 Задание

1. Для любого из двух наборов: Высшее образование.xls, Здравоохранение.xls реализуйте кластеризацию.
2. Выполните оценку качества кластеризации.
3. Предложите интерпретацию полученных кластеров.
4. Разработайте визуальные отчеты пользователю для изучения кластеров.

Для установки библиотек используйте материалы лекции. Там же рассмотрен алгоритм метода «локоть»

2 Результаты проделанной работы

На Рисунке 1 представлен созданный сценарий, включающий в себя алгоритм поиска количества кластеров – локоть, кластеризация методом k-means, кластеризация методом EM.

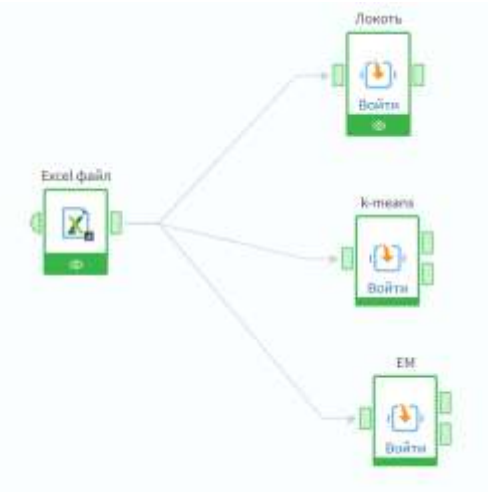

Рисунок 1 – Созданный сценарий

На рисунках 2-3 представлен сценарий для реализации метода Локоть, созданный по примеру, представленному в лекционных материалах.

Рисунок 2 – Подмодель «Локоть»

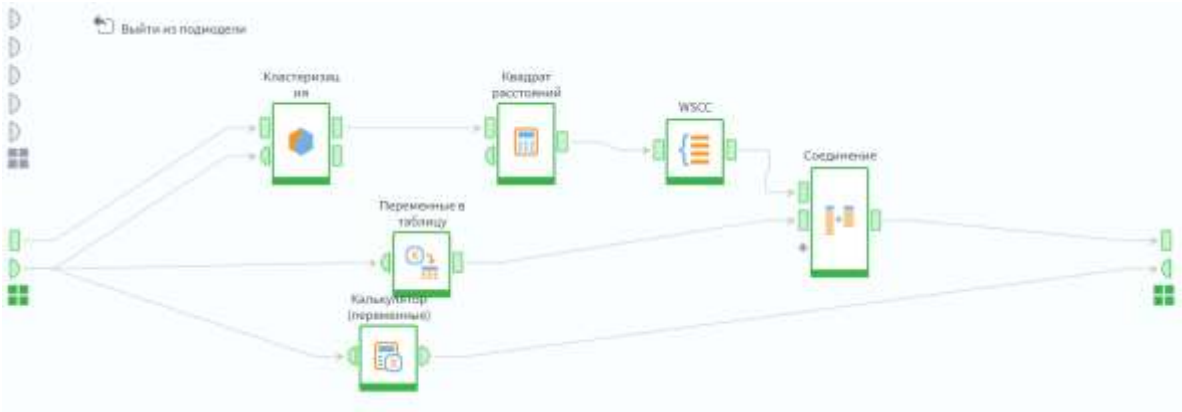

Рисунок 3 – Метод Локтя

Алгоритм, выполненный с применением компонента цикла, был запущен 8 раз. Полученные результаты изображены на рисунке 4. На их основе была построена диаграмма для определения оптимального количества кластеров (рисунок 5). Из анализа диаграммы видно, что квадрат расстояния начинает снижаться несущественно после 5 кластеров, поэтому было принято решение остановиться на значении 5.

Выход			
#	9.0 Квадрат расстояния|Сумма	12 Начальное число кластеров	12 Число итераций
1	433,13	2	8
2	304,83	3	7
3	243,43	4	6
4	219,52	5	5
5	191,30	6	4
6	173,37	7	3
7	156,52	8	2
8	148,96	9	1

Рисунок 4 – Результат работы цикла для разного числа кластеров

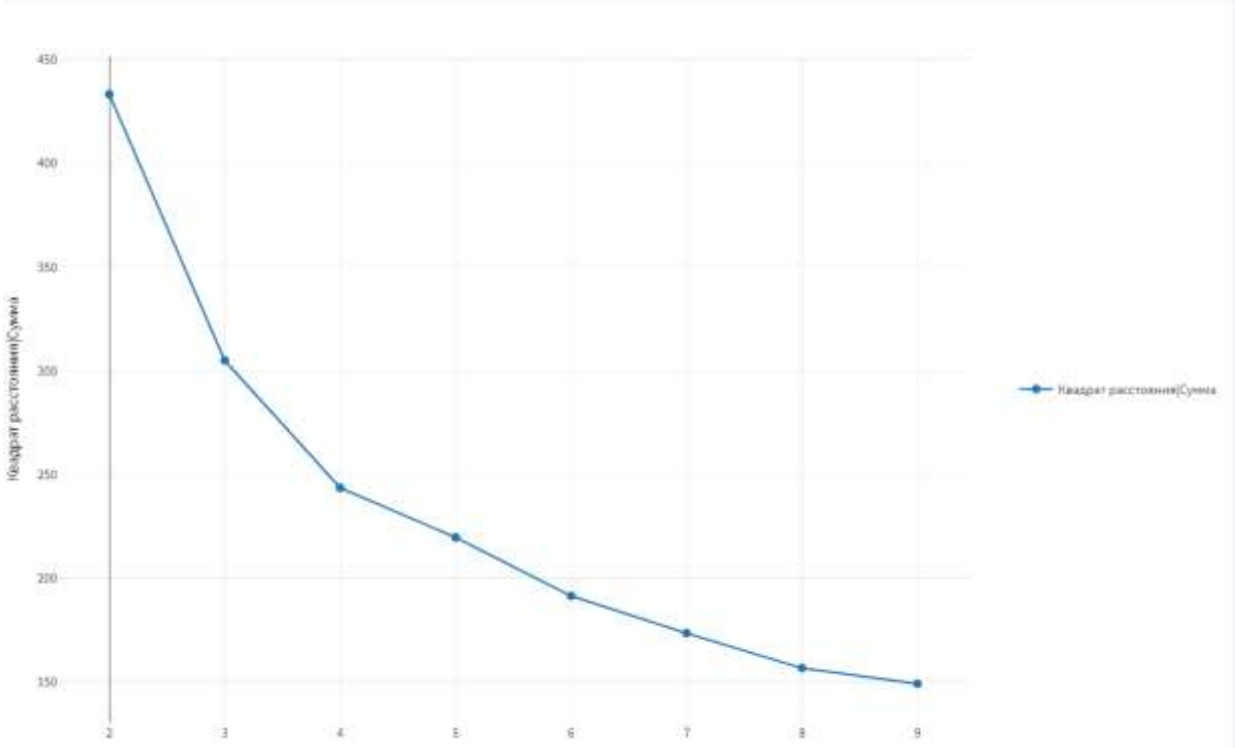

Рисунок 5 – Диаграмма количества кластеров по квадрату расстояний

Был применен компонент Кластеризация с использованием алгоритма k-means. Настройки компонента указаны на рисунках 6-7.

Настройка входных столбцов

Фильтрация

Метка	Имя	Вид данных	Назначение
1. Число образовательных организа...	_1__CHislo_obrazovatelnykh_organizatsi...	Непрерывн...	Используемое
2. Численность студентов, обучающ...	_2__CHislennost_studentov__obuchayus...	Непрерывн...	Используемое
3. Прием на обучение по программа...	_3__Priem_na_obuchenie_po_program...	Непрерывн...	Используемое
4. Выпуск бакалавров, специалисто...	_4__Vypusk_bakalavrov__spetsialistov_...	Непрерывн...	Используемое
5. Численность профессорско-преп...	_5__CHislennost_professorsko_prepoda...	Непрерывн...	Используемое
Регион	Region	Дискретный	Не задано

Рисунок 6 – Настройки входных данных кластеризации

Кластеризация

Автоопределение числа кластеров

Заданное число кластеров

Число кластеров 5

Автоматическое определение числа кластеров

Минимальное число кластеров 1

Максимальное число кластеров 10

Порог разделения кластеров 1

Рисунок 7 – Настройка количества кластеров

Для просмотра подробностей о созданных кластерах для компонента был создан визуализатор «Профили кластеров» (рисунки 8 – 13).

#	Метка поля	Тип	Итого	Кластер 0 %	Кластер 1	Кластер 2	Кластер 3	Кластер 4
			100%	39%	1,2%	28%	28%	3,7%
1	1. Число образ...		46	37	99,12	47	52	71
2	4. Выпуск бака...		55	52	96,9	45	47	97,3
3	3. Прием на обу...		58	56	94,6	48	54	97,3
4	2. Численность ...		60	57	96,9	48	55	97,3
5	5. Численность ...		87	61	99,12	66	68	97,3

Рисунок 8 – Профили кластеров

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	46	46	37	99,12	47	52	71
Минимум	2,9	2,9	8,9	40,0	10,8	2,9	14,9
Максимум	40,0	40,0	18,2	40,0	28,2	14,6	17,0
Среднее	13,6	13,6	13,2	40,0	17,2	9,1	15,9
Сумма	1114,6	1114,6	422,7	40,0	394,6	209,6	47,7
Стандартное от...	5,3	5,3	2,3	0,0	4,4	2,9	1,0
Размах	37,1	37,1	9,3	0,0	17,4	11,7	2,1
Пропуски	0	0	0	0	0	0	0
Значения	82	82	32	1	23	23	3
Количество ун...							

Рисунок 9 – Профили кластеров по числу образовательных организаций высшего образования и филиалов на начало учебного года (2015-2016 гг.) на 1 млн. чел. населения

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	60	60	57	96,9	48	55	97,3
Минимум	56	56	278	100	153	56	580
Максимум	616	616	488	100	306	286	616
Среднее	287	287	346	100	248	212	596
Сумма	23520	23520	11072	100	5693	4867	1787
Стандартное от...	98	98	53	0	41	49	18
Размах	560	560	209	0	153	230	36
Пропуски	0	0	0	0	0	0	0
Значения	82	82	32	1	23	23	3
Количество ун...							
Центр кластера			346	100	248	212	596

Рисунок 10 – Профили кластеров по численности студентов, обучающихся по программам бакалавриата, специалитета, магистратуры на начало учебного года (2015-2016 гг.) на 10 тыс. чел. населения

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	58	58	56	94,6	48	54	97,3
Минимум	11	11	88	20,0	34,2	11,2	165
Максимум	173	173	129	20,0	75,3	75,8	173
Среднее	71	71	88	20,0	58,9	50,1	170
Сумма	5845	5845	2810	20,0	1354,0	1151,9	509
Стандартное от...	29	29	16	0,0	11,8	12,2	4
Размах	161	161	61	0,0	41,1	64,6	8
Пропуски	0	0	0	0	0	0	0
Значения	82	82	32	1	23	23	3
Количество ун...							
Центр кластера			88	20,0	58,9	50,1	170

Рисунок 11 – Профили кластеров по приему на обучение по программам бакалавриата, специалитета, магистратуры (2015 г.) на 10 тыс. чел. населения

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	55	55	52	96,9	45	47	97,3
Минимум	12	12	55	20,0	41,1	12,4	129
Максимум	182	182	128	20,0	83,2	73,7	182
Среднее	76	76	92	20,0	67,6	53,7	156
Сумма	6212	6212	2932	20,0	1553,3	1236,1	469
Стандартное от...	27	27	15	0,0	10,0	14,5	27
Размах	170	170	72	0,0	42,1	61,3	53
Пропуски	0	0	0	0	0	0	0
Значения	82	82	32	1	23	23	3
Количество ун...							

Рисунок 12 – Профили кластеров по выпуску бакалавров, специалистов, магистров (2015 г.) на 10 тыс. чел. Населения

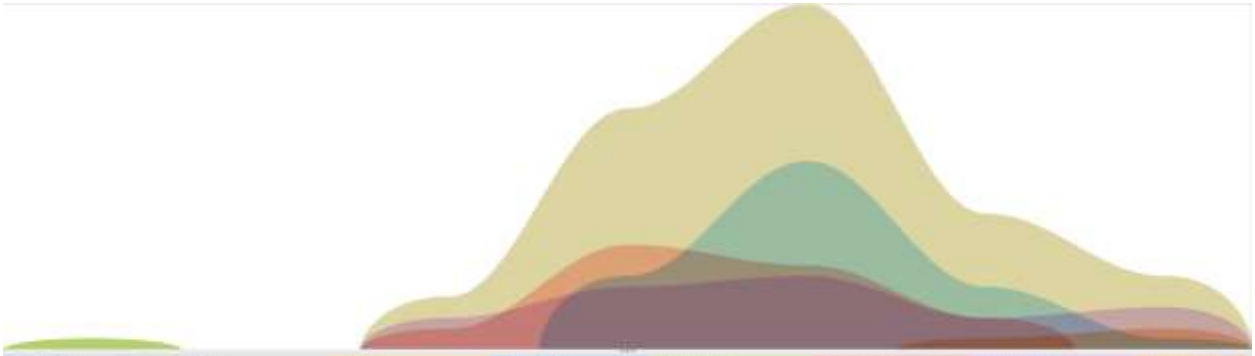

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	87	87	61	99,12	66	68	97,3
Минимум	14,0	14,0	44,2	14,0	39,7	35,5	67,2
Максимум	80,0	80,0	71,3	14,0	68,9	78,2	80,0
Среднее	55,3	55,3	56,5	14,0	51,5	56,8	72,8
Сумма	4532,1	4532,1	1809,4	14,0	1184,0	1306,2	218,5
Стандартное от...	10,6	10,6	6,8	0,0	8,2	11,8	6,5
Размах	66,0	66,0	27,1	0,0	29,2	42,7	12,8
Пропуски	0	0	0	0	0	0	0
Значения	82	82	32	1	23	23	3
Количество ун...							
Центр кластера			56,5	14,0	51,5	56,8	72,8

Рисунок 13 – Профили кластеров по численности профессорско-преподавательского персонала образовательных организаций высшего образования на 1000 студентов на начало учебного года (2015-2016 гг.)

Данные кластеры были оценены при помощи компонента meta-silhouettes (рисунки 14-15).

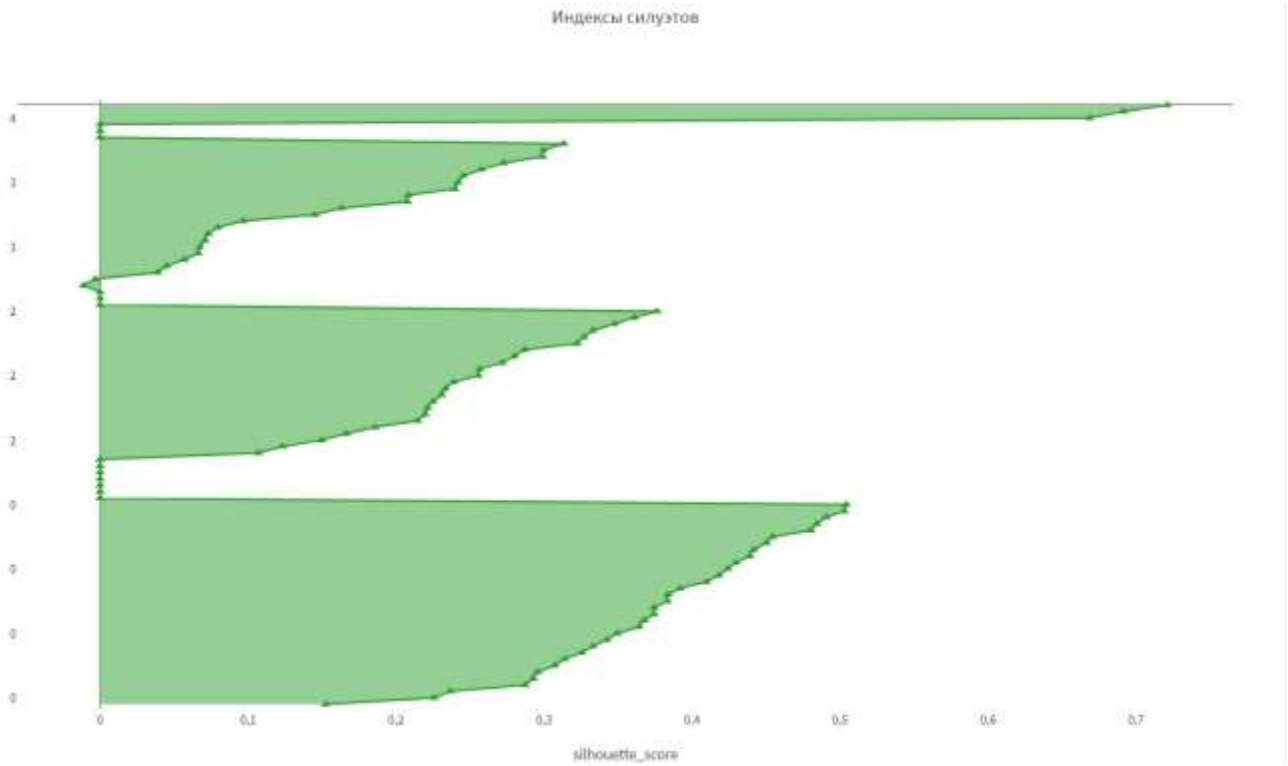

Рисунок 14 – Индексы силуэтов

№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,27
2	ab Quality	Качество кластеризации	Среднее

Рисунок 15 – Оценка по индеку силуэта

Изображение на рисунке 14 показывает, что в процессе кластеризации были обнаружены аномалии. Решено было удалить их из набора данных. Для этого были выявлены регионы с отрицательными значениями индексов силуэтов (рисунок 16), которые затем были исключены с использованием компонента Фильтр (рисунок 17).

#	12 Номер строки	9.0 Индекс силуэта 1
1	260	-0,01131806531
2	250	-0,00320800023
3	500	0
4	240	0,03885960471
5	230	0,04482654263
6	220	0,0569486654
7	210	0,06635498692
8	200	0,06746264283
9	190	0,0709531648
10	180	0,0730401025

Рисунок 16 – Регионы, индексы силуэтов которых отрицательны

Соответствуют условию | Не соответствуют условию

#	Регион	1. Число обр...	2. Численность ст...	3. Прием на обуч...	4. Выпуск бакалавров, специа...	5. Численность проф...
1	Сахалинская область	10,27	182,75	47,23	39,01	38,20
2	Чукотский автономный округ	40,00	100,00	20,00	20,00	14,00
3	Республика Крым	5,77	238,07	69,55	38,28	67,03

Рисунок 17 – Исключенные значения

Проанализированные исключенные значения вызвали определенные вопросы. В Сахалинской области отмечается необычно высокое количество учреждений по сравнению с другими показателями, а показатели Чукотского автономного округа выглядят нереалистично в целом (даже по формату данных). В Республике Крым, хотя показатели не кажутся столь аномальными, возникают сомнения относительно соотношения числа образовательных учреждений к числу профессоров.

Оставшиеся данные были снова разделены на 5 кластеров, а профили этих кластеров представлены на Рисунках 18–23.

#	Метка поля	Тип	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
			100%	35%	3,8%	30%	16%	14%
1	4. Выпуск бакал...		51	38	97,2	57	48	46
2	1. Число образо...		54	40	74	46	78	46
3	3. Прием на обуч...		54	43	97,2	61	45	47
4	5. Численность ...		62	45	97,2	48	57	90
5	2. Численность с...		58	46	97,2	68	48	52

Рисунок 18 – Профили кластеров

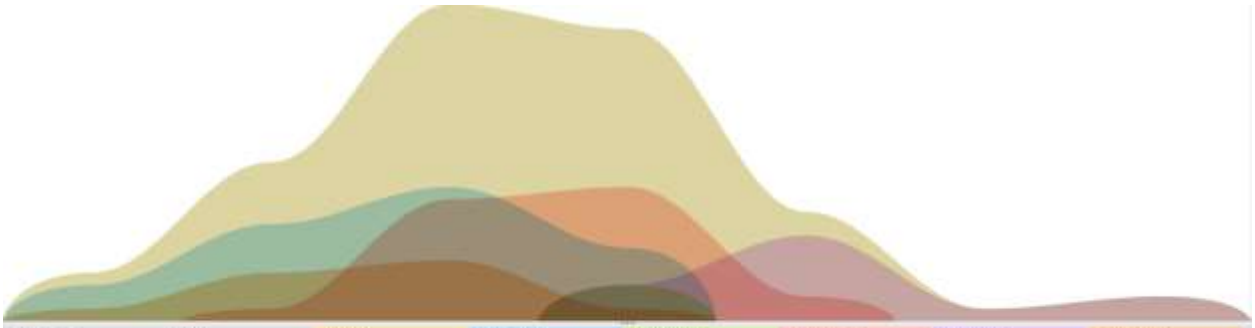

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	54	54	40	74	46	78	46
Минимум	2,9	2,9	2,9	14,9	9,7	15,5	4,7
Максимум	28,2	28,2	16,0	17,0	18,2	28,2	16,8
Среднее	13,4	13,4	11,0	15,9	13,6	19,9	10,6
Сумма	1058,5	1058,5	308,6	47,7	327,2	258,4	116,7
Стандартное от...	4,4	4,4	3,1	1,0	2,2	3,9	3,3
Размах	25,3	25,3	13,1	2,1	8,5	12,6	12,2
Пропуски	0	0	0	0	0	0	0
Значения	79	79	28	3	24	13	11
Количество ун...							
Центр кластера			11,0	15,9	13,6	19,9	10,6

Рисунок 19 – Профили кластеров по числу образовательных организаций высшего образования и филиалов на начало учебного года (2015-2016 гг.) на 1 млн. чел. населения

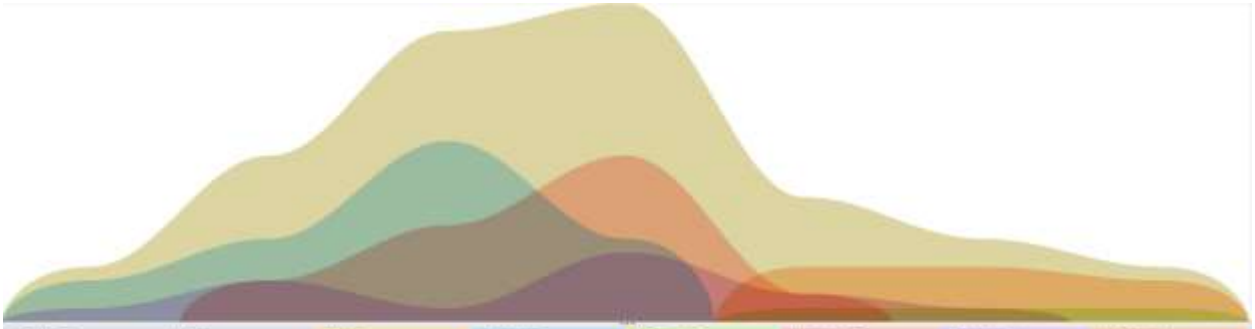

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	62	62	45	97,2	48	57	90
Минимум	35,5	35,5	35,5	67,2	44,2	39,7	63,0
Максимум	80,0	80,0	59,5	80,0	66,5	68,9	78,2
Среднее	55,9	55,9	49,9	72,8	54,9	54,7	69,8
Сумма	4412,9	4412,9	1397,7	218,5	1317,9	711,4	767,5
Стандартное от...	9,4	9,4	5,8	6,5	5,0	9,0	5,2
Размах	44,6	44,6	24,0	12,8	22,3	29,2	15,2
Пропуски	0	0	0	0	0	0	0
Значения	79	79	28	3	24	13	11
Количество ун...							
Центр кластера			49,9	72,8	54,9	54,7	69,8

Рисунок 20 – Профили кластеров по численности студентов, обучающихся по программам бакалавриата, специалитета, магистратуры на начало учебного года (2015-2016 гг.) на 10 тыс. чел. населения

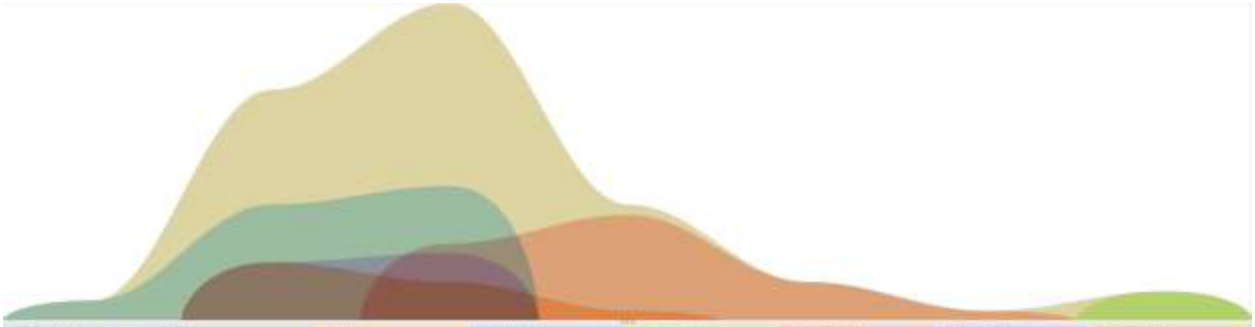

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	54	54	43	97,2	61	45	47
Минимум	11	11	11,2	165	69	36,1	41,9
Максимум	173	173	75,8	173	129	72,9	98,6
Среднее	72	72	55,6	170	92	58,2	62,2
Сумма	5712	5712	1557,0	509	2205	756,3	684,7
Стандартное от...	29	29	14,3	4	16	12,5	17,4
Размах	161	161	64,6	8	60	36,8	56,7
Пропуски	0	0	0	0	0	0	0
Значения	79	79	28	3	24	13	11
Количество ун...							
Центр кластера			55,6	170	92	58,2	62,2

Рисунок 21 – Профили кластеров по приему на обучение по программам бакалавриата, специалитета, магистратуры (2015 г.) на 10 тыс. чел. населения

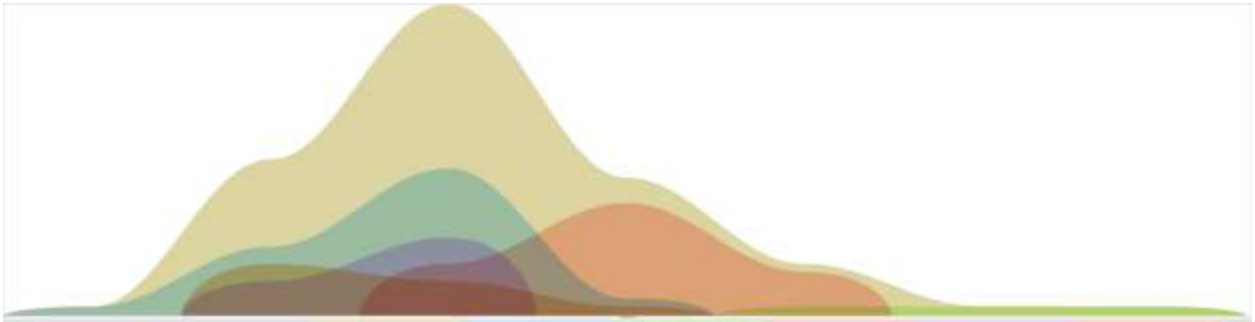

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	51	51	38	97,2	57	46	46
Минимум	12	12	12,4	129	80	57,7	37,2
Максимум	182	182	87,6	182	128	82,0	87,4
Среднее	77	77	62,8	156	96	68,9	61,8
Сумма	6114	6114	1758,2	469	2311	896,1	680,3
Стандартное от...	26	26	15,8	27	13	9,0	15,6
Размах	170	170	75,3	53	48	24,3	50,2
Пропуски	0	0	0	0	0	0	0
Значения	79	79	28	3	24	13	11
Количество ун...							
Центр кластера			62,8	156	96	68,9	61,8

Рисунок 22 – Профили кластеров по выпуску бакалавров, специалистов, магистров (2015 г.) на 10 тыс. чел. Населения

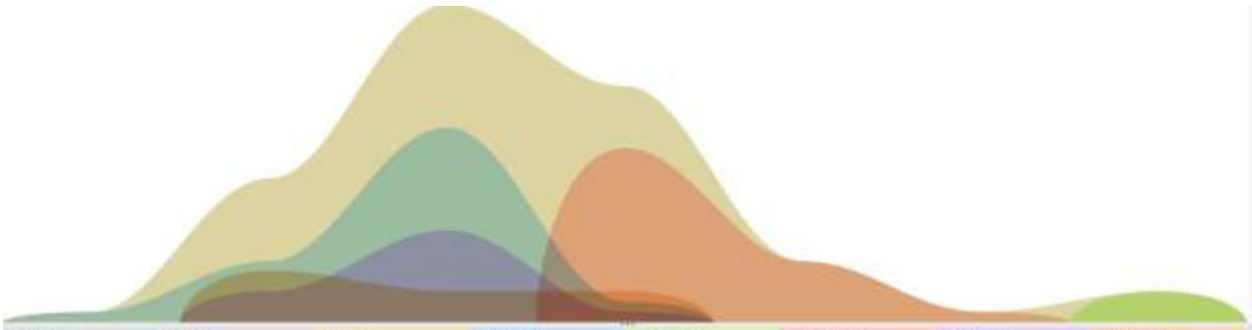

Атрибут	Итого	Итого	Кластер 0	Кластер 1	Кластер 2	Кластер 3	Кластер 4
Значимость	58	58	46	97,2	68	48	52
Минимум	56	56	56	580	301	187	153
Максимум	616	616	305	616	488	306	365
Среднее	291	291	236	596	361	250	244
Сумма	22999	22999	6609	1787	8671	3248	2684
Стандартное от...	96	96	51	18	50	41	69
Размах	560	560	249	36	186	119	212
Пропуски	0	0	0	0	0	0	0
Значения	79	79	28	3	24	13	11
Количество ун...							
Центр кластера			236	596	361	250	244

Рисунок 23 – Профили кластеров по численности профессорско-преподавательского персонала образовательных организаций высшего образования на 1000 студентов на начало учебного года (2015-2016 гг.)

Таблица 1 – Интерпретация результатов кластерного анализа

Кластер	Условное наименование	Мощность кластера	Входящие регионы (кол-во)
0	Низкое качество образования	35%	28
1	Лучшее качество образования	3,8%	3
2	Высокое качество образования	30%	24
3	Качество образования чуть ниже среднего	16%	13
4	Среднее качество образования	14%	11

С использованием компонента meta-silhouettes была проведена оценка качества кластеризации. На рисунке 24 представлены индексы силуэтов для каждого кластера, а на рисунке 25 – общая оценка кластеризации. После исключения аномальных значений значения оценки кластеров увеличились. Однако на рисунке 24 можно наблюдать появление новых аномалий, которые были рассмотрены отдельно. Они были рассмотрены отдельно, но их значения не были столь существенны, как при первом выделении аномалий.

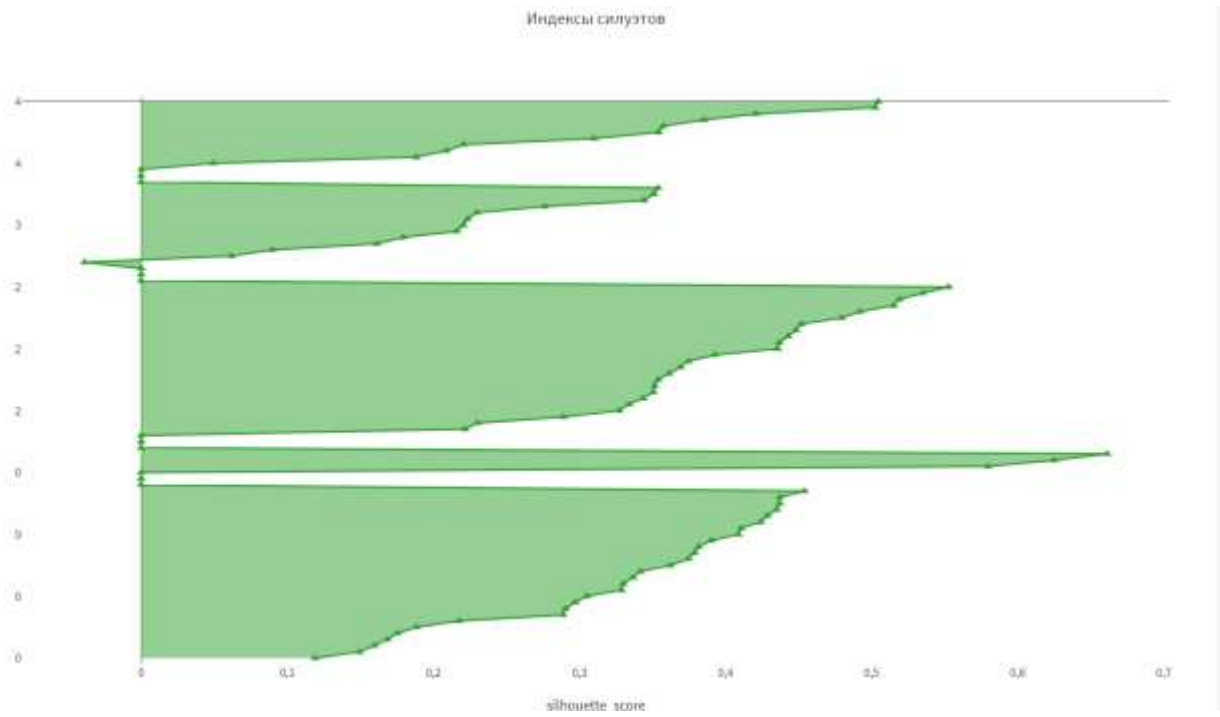

Рисунок 24 – Индексы силуэтов

№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,34
2	ab Quality	Качество кластеризации	Среднее

Рисунок 25 – Оценка по индеку силуэта

Далее была выполнена кластеризация с использованием тех же анализируемых данных, но с применением алгоритма EM (см. рисунки 26–31). Было проведено сравнение двух методов, поэтому количество кластеров было выбрано равным 5.

Можно чётко увидеть, что один класс значительно превосходит остальные. Это видно по профилям, представленным на рисунках. При этом на рисунке 26 можно заметить, что показатели значимости каждого кластера имеют более выраженные различия, что делает их анализ более удобным.

#	Метка поля	Тип	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
			100%	66%	13%	9,8%	6,1%	4,0%
1	1. Числ образ...		35	22	46	51	64	70
2	2. Численность ...		50	25	46	64	59	96,4
3	3. Прием на обу...		46	24	57	44	59	96,4
4	4. Выпуск бака...		48	28	56	58	57	96,4
5	5. Численность ...		67	38	64	80	95,5	67

Рисунок 26 – Профили кластеров

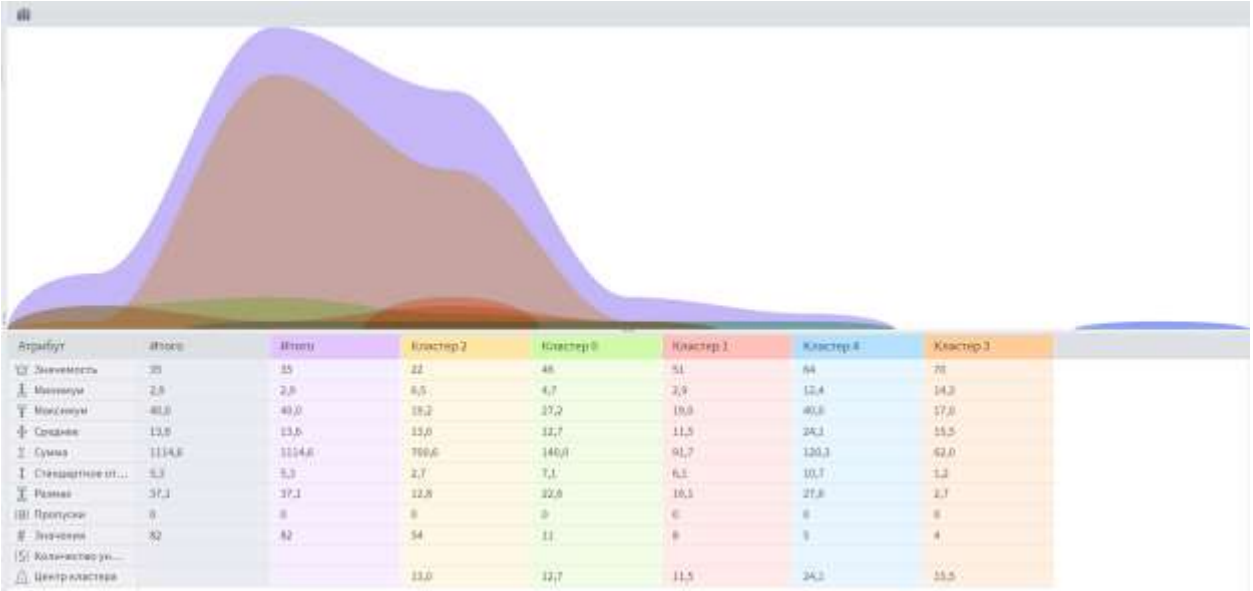

Атрибут	Итого	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
Значимость	35	35	22	46	51	64	70
Минимум	2,9	2,9	6,5	4,7	2,9	12,4	14,3
Максимум	40,0	40,0	19,2	27,2	19,0	40,0	17,0
Среднее	13,6	13,6	13,0	12,7	11,5	24,1	15,5
Сумма	1114,6	1114,6	700,6	140,0	91,7	120,3	62,0
Стандартное от...	5,3	5,3	2,7	7,1	6,1	10,7	1,2
Размах	37,1	37,1	12,8	22,6	16,1	27,6	2,7
Пропуски	0	0	0	0	0	0	0
Значения	82	82	54	11	8	5	4
Количество кл...							
Центр кластера			13,0	12,7	11,5	24,1	15,5

Рисунок 27 – Профили кластеров по числу образовательных организаций высшего образования и филиалов на начало учебного года (2015-2016 гг.) на 1 млн. чел. населения

Атрибут	Итого	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
Значимость	50	50	35	46	64	50	16,4
Минимум	56	56	153	153	56	100	488
Максимум	618	618	448	300	418	365	618
Среднее	287	287	282	213	228	260	569
Сумма	23520	23520	15770	2348	1827	1300	2276
Стандартное от...	98	98	65	41	106	97	56
Размах	560	560	295	151	362	265	129
Пропуски	0	0	0	0	0	0	0
Значения	82	82	54	11	8	5	4
Количество кл...							
Центр кластера			292	213	228	260	569

Рисунок 28 – Профили кластеров по численности студентов, обучающихся по программам бакалавриата, специалитета, магистратуры на начало учебного года (2015-2016 гг.) на 10 тыс. чел. населения

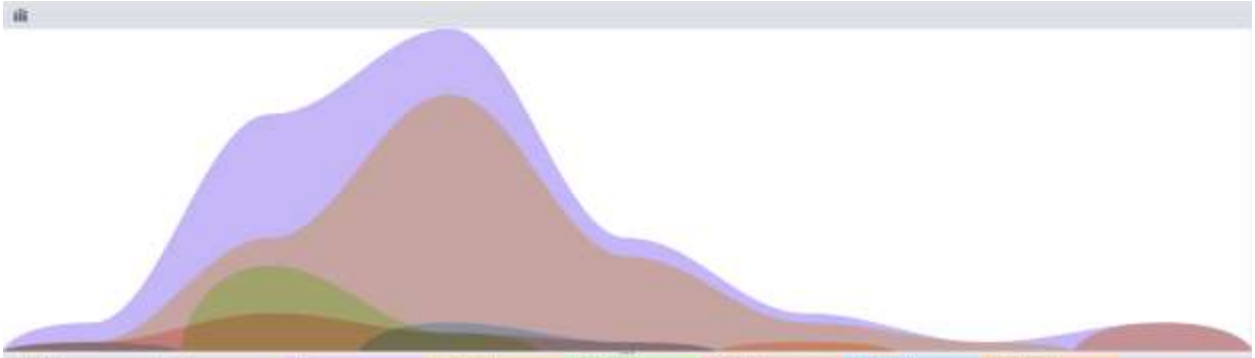

Атрибут	Итого	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
Значимость	48	48	24	57	44	59	96,4
Минимум	11	11	34	41,9	11,2	20,0	123
Максимум	173	173	129	65,5	93,7	96,6	173
Среднее	71	71	72	52,3	52,2	65,8	158
Сумма	5845	5845	3890	575,7	417,8	329,2	622
Стандартное от...	29	29	20	6,6	25,0	28,7	24
Размах	161	161	95	23,7	82,5	78,6	49
Пропуски	0	0	0	0	0	0	0
Значения	82	82	54	11	8	5	4
Количество ун...							
Центр кластера			72	52,3	52,2	65,8	158

Рисунок 29 – Профили кластеров по приему на обучение по программам бакалавриата, специалитета, магистратуры (2015 г.) на 10 тыс. чел. населения

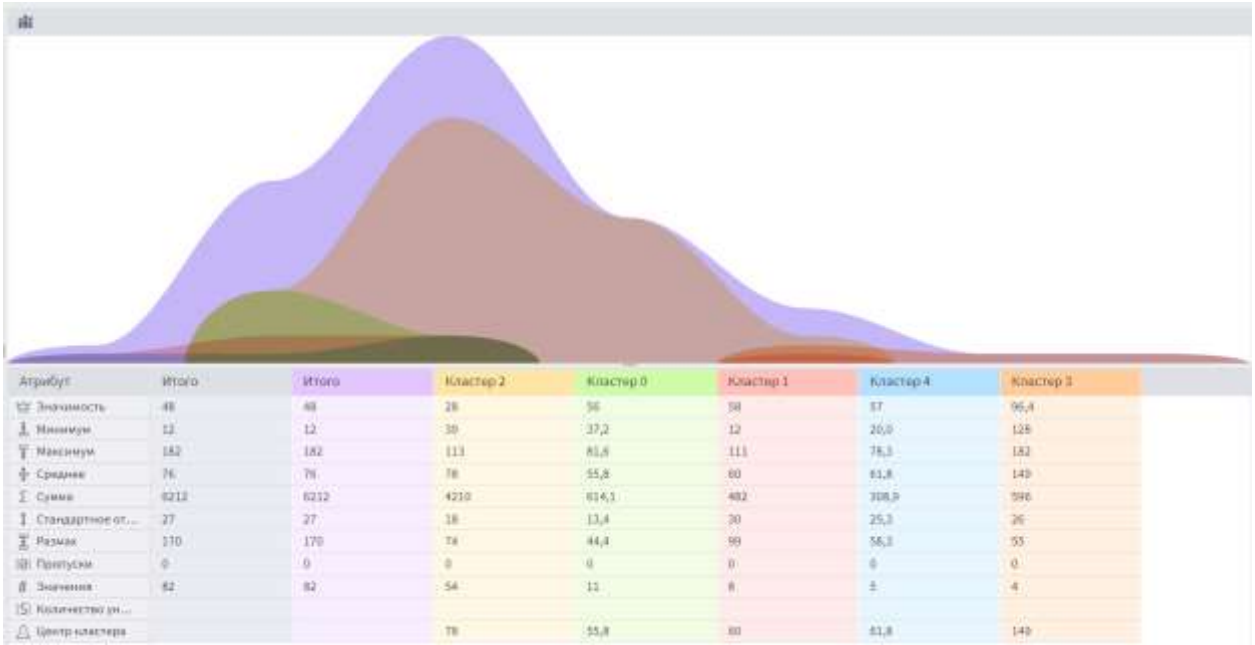

Атрибут	Итого	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
Значимость	48	48	28	56	58	57	96,4
Минимум	12	12	30	37,2	12	20,0	128
Максимум	182	182	113	81,6	111	78,3	182
Среднее	76	76	78	55,8	60	61,8	149
Сумма	6212	6212	4210	614,1	482	308,9	596
Стандартное от...	27	27	18	13,4	30	25,3	26
Размах	170	170	74	44,4	99	58,3	53
Пропуски	0	0	0	0	0	0	0
Значения	82	82	54	11	8	5	4
Количество ун...							
Центр кластера			78	55,8	60	61,8	149

Рисунок 30 – Профили кластеров по выпуску бакалавров, специалистов, магистров (2015 г.) на 10 тыс. чел. Населения

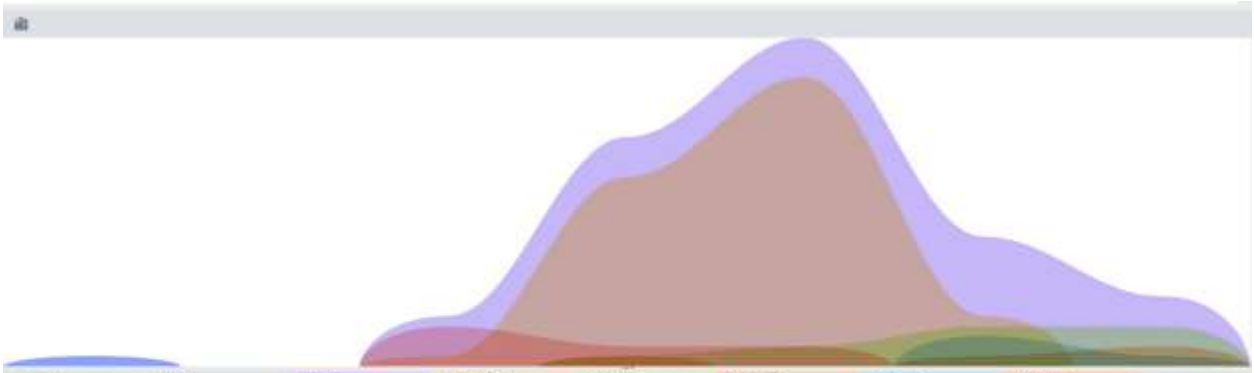

Атрибут	Итого	Итого	Кластер 2	Кластер 0	Кластер 1	Кластер 4	Кластер 3
Значимость	87	87	38	84	80	95,5	87
Минимум	14,0	14,0	38,2	42,4	35,5	14,0	44,2
Максимум	80,0	80,0	66,5	78,2	52,5	71,3	80,0
Среднее	55,3	55,3	53,7	63,9	44,8	57,3	65,7
Сумма	4532,1	4532,1	2898,1	725,0	358,5	287,7	262,8
Стандартное от...	10,6	10,6	6,1	10,1	6,4	24,6	15,3
Размах	66,0	66,0	28,3	35,7	17,1	57,3	35,8
Пропуски	0	0	0	0	0	0	0
Значения	82	82	54	11	8	5	4
Количество ун...							
Центр кластера			53,7	63,9	44,8	57,3	65,7

Рисунок 31 – Профили кластеров по численности профессорско-преподавательского персонала образовательных организаций высшего образования на 1000 студентов на начало учебного года (2015-2016 гг.)

Данные кластеры были оценены при помощи компонента meta-silhouettes (рисунки 32 – 33).

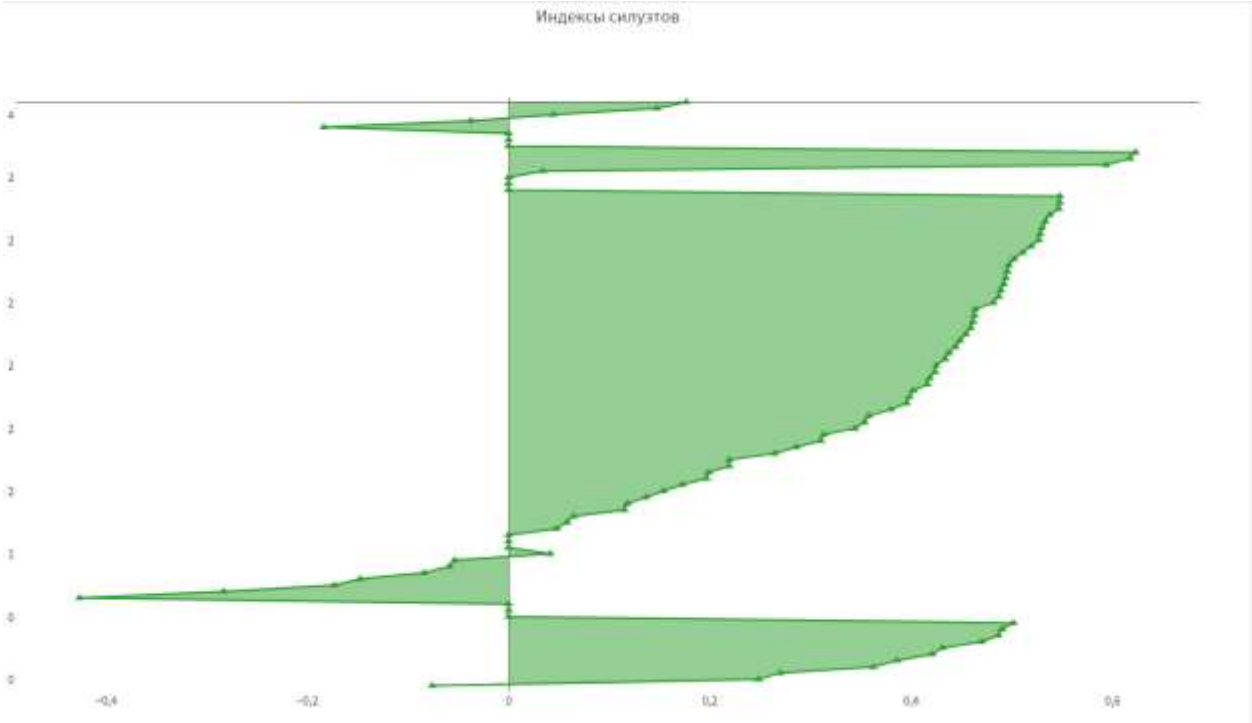

Рисунок 32 – Индексы силуэтов

Индексы силуэтов	Индекс силуэта		
№	Имя	Метка	Значение
1	SilhouetteCoefficient	Индекс силуэта	0,31
2	Quality	Качество кластеризации	Среднее

Рисунок 33 – Оценка по индеку силуэта

На рисунке 32 видно, что в процессе кластеризации было обнаружено большое количество аномалий. Было принято решение исключить их из набора данных, как и в алгоритме k-means.

Для этого были определены области, индексы силуэтов которых имели отрицательное значение (рисунок 34). Эти области были удалены с помощью инструмента «Фильтр» (рисунок 35).

#	Номер строки	Индекс силуэта	Класт
1	710	-0,4262352712	1
2	700	-0,2831244662	1
3	50	-0,1837746109	4
4	690	-0,1733559219	1
5	680	-0,147653417	1
6	670	-0,08409526253	1
7	820	-0,07591718301	0
8	660	-0,05899446304	1
9	650	-0,0535187033	1
10	40	-0,03767888681	4
11	90	0,03372169554	3
12	640	0,04131782524	1
13	30	0,04438250446	4
14	630	0,04747746986	2
15	620	0,0576094904	2
16	610	0,06447622728	2

Рисунок 34 – Регионы, индексы силуэтов которых отрицательны

#	Регион	1. Число образователь...	2. Численность студ...	3. Прием на обучен...	4. Выпуск бакал...	5. Численность профес...
1	Ленинградская область	8,43	55,65	11,24	12,37	35,45
2	Чеченская Республика	2,87	237,45	52,37	47,35	41,72
3	Республика Марий Эл	7,29	285,71	75,80	64,14	51,22
4	Республика Хакасия	5,59	160,15	44,69	37,24	51,86
5	Камчатский край	18,89	202,53	44,30	66,46	44,38
6	Хабаровский край	14,99	417,54	93,70	110,94	52,53
7	Еврейская автономная область	18,07	186,75	36,14	60,24	39,68
8	Чукотский автономный округ	40,00	100,00	20,00	20,00	14,00
9	Республика Крым	5,77	238,07	65,55	38,28	67,03
10	г. Севастополь	16,83	365,38	98,56	35,29	71,32

Рисунок 35 – Исключенные значения

Исключённые значения были проанализированы. В отличие от значений, исключаемых в алгоритме k-means, некоторые из них не показались достаточно аномальными. Например, это касается Республики Марий Эл и Республики Хакасия.

Однако также были выявлены интересные аномалии. Среди них — Ленинградская область, в которой слишком низкая численность студентов, абитуриентов и выпускников. Ещё одна аномалия — Чеченская республика, где слишком малое количество образовательных организаций по сравнению с остальными показателями.

Оставшиеся данные были разделены на 5 кластеров. Профили кластеров представлены на рисунках 36-41. Распределение регионов по кластерам стало более равномерным в числовом выражении. Однако различия между некоторыми показателями стали трудноразличимыми. Возможно, на более крупном наборе данных этой особенности не было бы.

#	Метка поля	Тип	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
			100%	32%	24%	18%	14%	13%
1	1. Число образ...		54	50	64	50	47	57
2	2. Численность ...		50	37	38	60	59	66
3	3. Прием на обу...		51	38	41	61	59	76
4	4. Выпуск бака...		48	38	41	60	50	70
5	5. Численность ...		62	49	49	59	53	74

Рисунок 36 – Профили кластеров

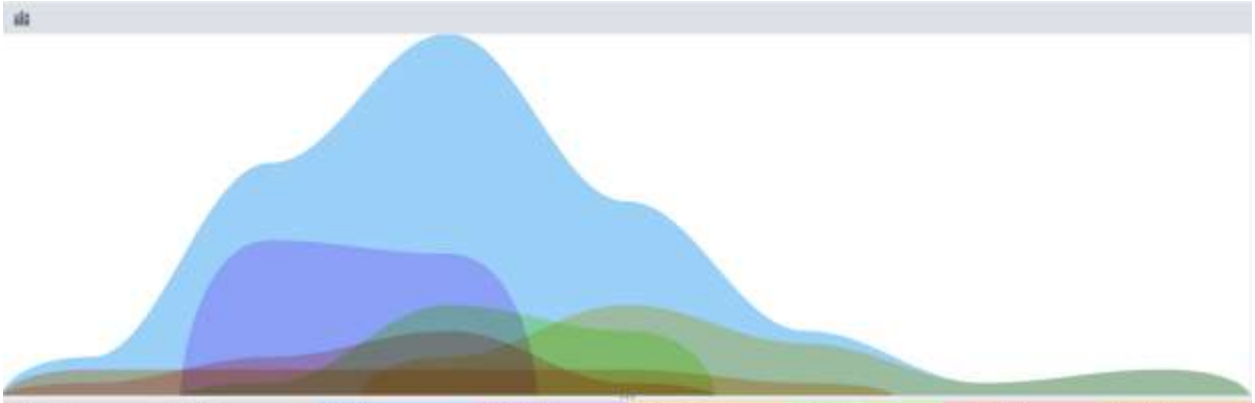

Атрибут	Итого	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
Значимость	54	54	50	64	50	47	57
Минимум	4,7	4,7	8,9	11,6	10,3	6,5	4,7
Максимум	28,2	28,2	13,8	28,2	17,0	15,5	18,4
Среднее	13,6	13,6	11,4	18,1	13,9	11,9	12,0
Сумма	975,8	975,8	261,2	306,9	181,1	118,8	108,0
Стандартное от...	4,1	4,1	1,4	4,5	1,9	2,9	4,9
Размах	23,5	23,5	4,9	16,6	6,7	9,0	13,7
Пропуски	0	0	0	0	0	0	0
Значения	72	72	23	17	13	10	9
Количество ун...							
Центр кластера			11,4	18,1	13,9	11,9	12,0

Рисунок 37 – Профили кластеров по числу образовательных организаций высшего образования и филиалов на начало учебного года (2015-2016 гг.) на 1 млн. чел. населения

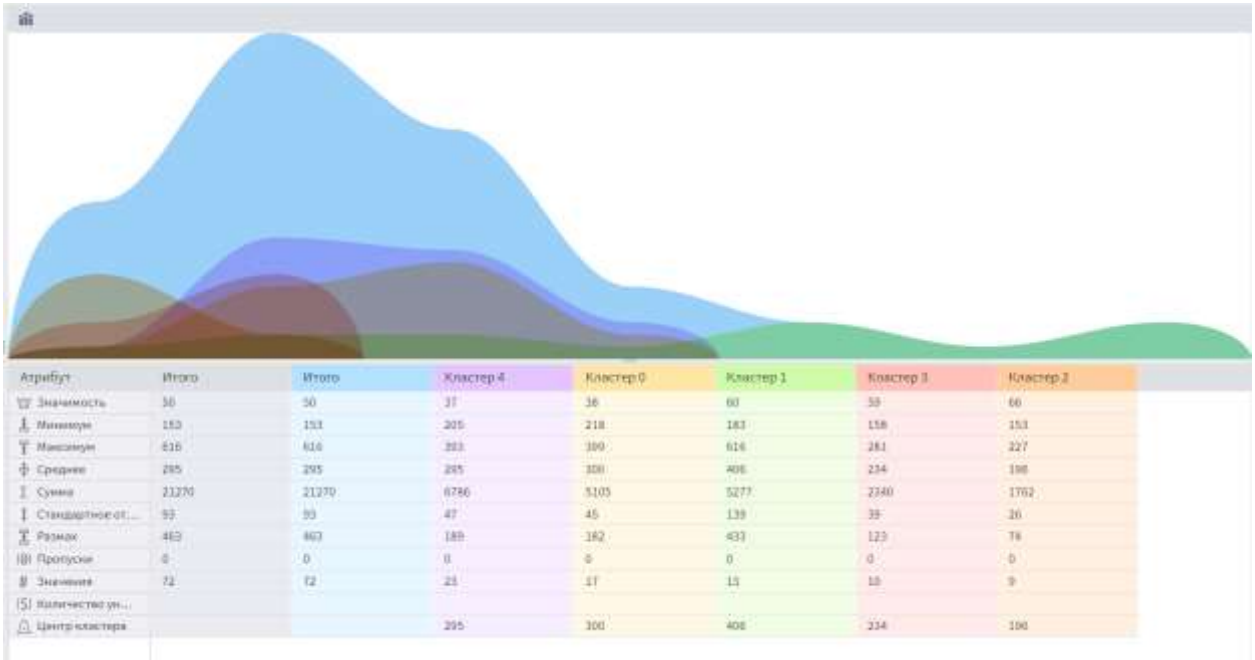

Атрибут	Итого	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
Значимость	50	50	37	36	60	59	66
Минимум	153	153	205	218	183	158	153
Максимум	616	616	303	300	616	281	227
Среднее	295	295	295	300	408	234	198
Сумма	21270	21270	6786	5105	5277	2340	1762
Стандартное от...	93	93	47	45	139	39	26
Размах	463	463	189	182	433	123	74
Пропуски	0	0	0	0	0	0	0
Значения	72	72	23	17	13	10	9
Количество ун...							
Центр кластера			295	300	408	234	198

Рисунок 38 – Профили кластеров по численности студентов, обучающихся по программам бакалавриата, специалитета, магистратуры на начало учебного года (2015-2016 гг.) на 10 тыс. чел. населения

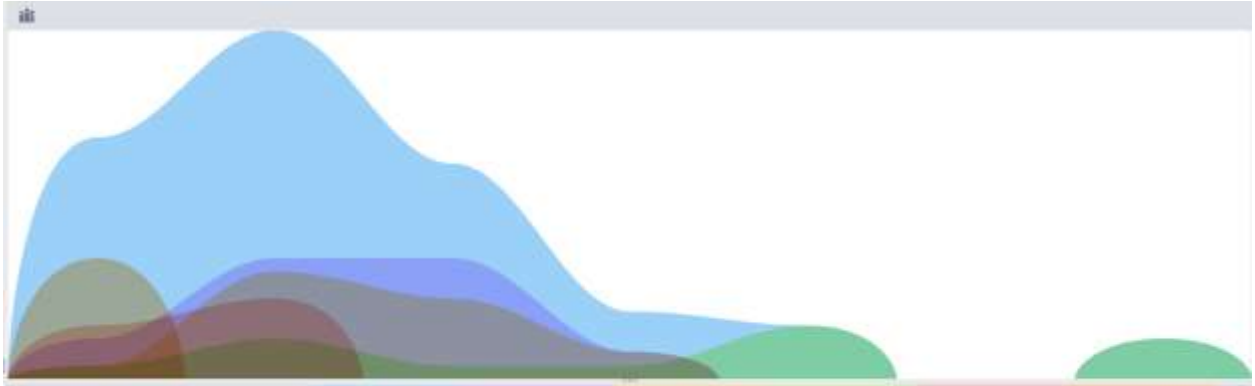

Атрибут	Итого	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
Значимость	51	51	38	41	61	59	76
Минимум	34	34	46	51	47	35,9	34,2
Максимум	173	173	100	106	173	71,7	51,1
Среднее	74	74	72	74	109	55,8	45,1
Сумма	5302	5302	1663	1261	1414	558,2	406,0
Стандартное от...	29	29	14	14	44	10,6	5,9
Размах	139	139	54	55	125	35,8	16,9
Пропуски	0	0	0	0	0	0	0
Значения	72	72	23	17	13	10	9
Количество ун...							
Центр кластера			72	74	109	55,8	45,1

Рисунок 39 – Профили кластеров по приему на обучение по программам бакалавриата, специалитета, магистратуры (2015 г.) на 10 тыс. чел. населения

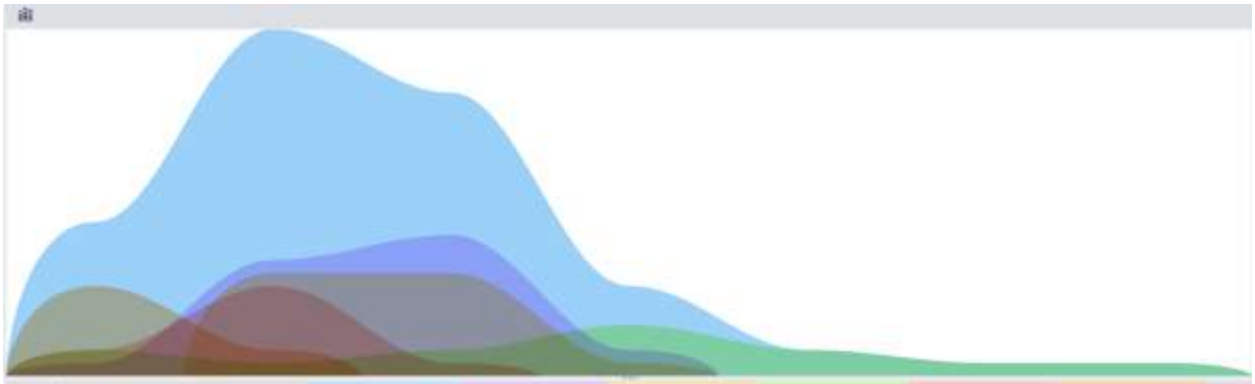

Атрибут	Итого	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
Значимость	46	46	36	41	60	50	76
Минимум	37	37	55	60	39	44,3	37,2
Максимум	182	182	111	105	182	83,2	72,2
Среднее	79	79	82	79	103	65,4	52,7
Сумма	5699	5699	1881	1348	1341	653,7	474,6
Стандартное от...	25	25	15	11	41	10,8	10,3
Размах	145	145	56	45	143	38,8	35,0
Пропуски	0	0	0	0	0	0	0
Значения	72	72	23	17	13	10	9
Количество ун...							
Центр кластера			82	79	103	65,4	52,7

Рисунок 40 – Профили кластеров по выпуску бакалавров, специалистов, магистров (2015 г.) на 10 тыс. чел. Населения

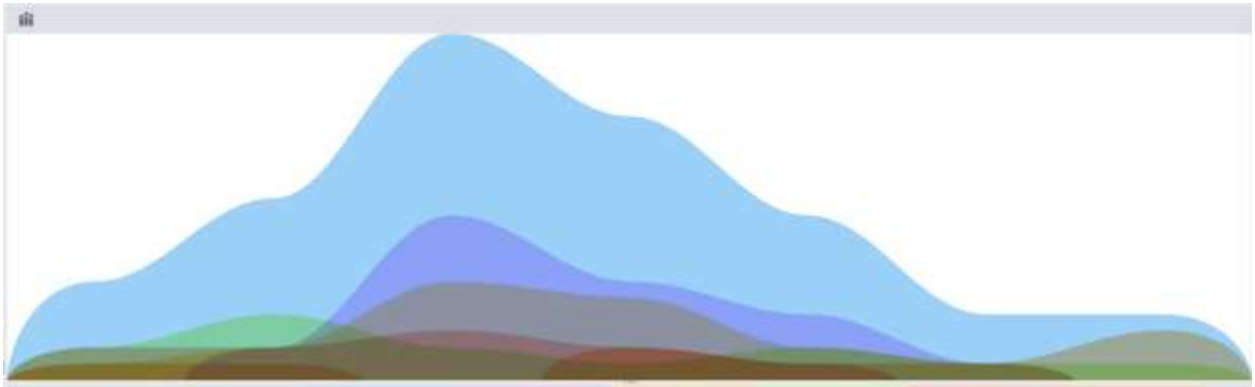

Атрибут	Итого	Итого	Кластер 4	Кластер 0	Кластер 1	Кластер 3	Кластер 2
Значимость	62	62	49	49	59	53	74
Минимум	38,2	38,2	44,8	42,4	38,2	41,7	43,3
Максимум	80,0	80,0	70,4	68,9	80,0	65,4	78,2
Среднее	56,4	56,4	56,6	55,8	55,2	51,8	64,0
Сумма	4063,0	4063,0	1302,1	949,3	718,1	517,8	575,6
Стандартное от...	9,1	9,1	6,2	6,1	12,9	7,1	12,8
Размах	41,8	41,8	25,6	26,5	41,8	23,7	34,3
Пропуски	0	0	0	0	0	0	0
Значения	72	72	23	17	13	10	9
Количество ун...							
Центр кластера			56,6	55,8	55,2	51,8	64,0

Рисунок 41 – Профили кластеров по численности профессорско-преподавательского персонала образовательных организаций высшего образования на 1000 студентов на начало учебного года (2015-2016 гг.)

Эти кластеры были проанализированы с использованием meta-silhouettes (рис. 42–43). Результаты показали, что индексы силуэтов в основном отрицательные, а значение самого индекса силуэта значительно снизилось. Это говорит о том, что для алгоритма EM грубое исключение данных на основе индексов не подходит. Требуется более детальное изучение входных данных или применение другого метода оценки.

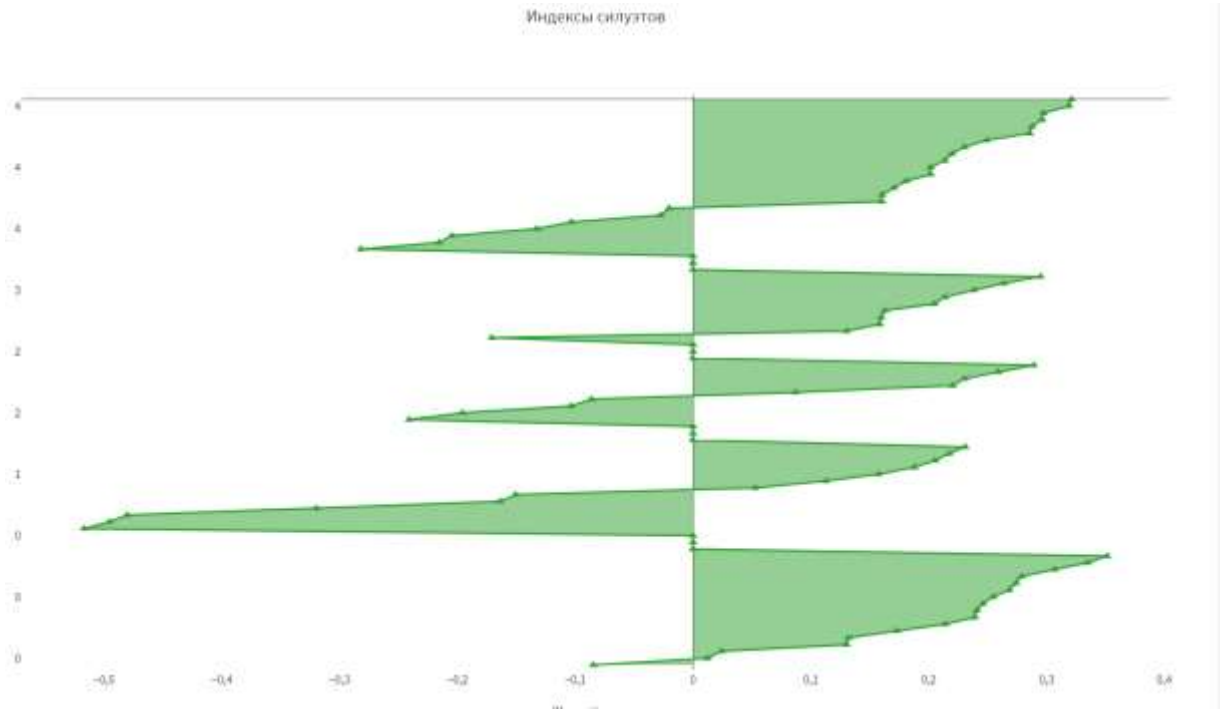

Рисунок 42 – Индексы силуэтов

№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,10
2	ab Quality	Качество кластеризации	Низкое

Рисунок 43 – Оценка по индеку силуэта

Так как полученные после исключения кластеры имеют низкое качество кластеризации, интерпретация производилась по класстерам до исключения значений.

Таблица 2 – Интерпретация результатов кластерного анализа

Кластер	Условное наименование	Мощность кластера	Входящие регионы (кол-во)
0	Качество образования чуть ниже среднего	13%	11
1	Среднее качество образования	9,8%	8
2	Низкое качество образования	66%	54
3	Лучшее качество образования	4%	4
4	Высокое качество образования	6,1%	5

Вывод

В рамках лабораторной работы была выполнена кластеризация данных из набора «Высшее образование.xls».

Работа включала в себя несколько этапов: оценку качества кластеризации, анализ полученных результатов и их интерпретацию. Для удобства изучения полученных кластеров были созданы наглядные отчёты. Также были обнаружены и частично исправлены аномалии, возникшие в процессе кластеризации.