ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук		Н.В. Богословская
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №7

РЕГРЕССИЯ: ЛИНЕЙНАЯ, ПОЛИНОМИАЛЬНАЯ, ЛОГИСТИЧЕСКАЯ

по курсу: БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №	4127		А. А. Костина
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2024

1 Задание

В файле Денежные доходы.xlsx имеются данные о среднедушевых денежных доходах населения и о тех факторах, которые могут влиять на них. Требуется установить зависимость среднедушевых доходов от отобранных факторов.

В файле Число амбулаторно-поликлинических организаций.xlsx имеются данные о числе амбулаторно-поликлинических организаций в Российской Федерации за 19 лет. Требуется промоделировать временное изменение числа амбулаторно-поликлинических организаций.

В файле Клиенты торговой сети.xlsx приведены данные о клиентах торговой сети и их реакции на адресные предложения о приобретении новой линии продуктов. Информация о клиентах содержит такие данные: пол клиента; возрастная группа покупателя; статус скидочной карты (бронзовая, серебряная, золотая, платиновая); число месяцев с момента получения скидочной карты; общая сумма потраченных средств; сегмент совокупного семейного дохода покупателя. Результирующий признак – количество купленных товаров из группы новых товаров.

Требуется, используя 70% случайную выборку клиентов, создать модель для оценки склонности клиентов к приобретению продуктов новой линии. Выбросы и экстремальные значения оставить без изменения.

2 Результаты проделанной работы

На рисунке 1 представлен сценарий, в котором реализованы линейная, нелинейная и логистическая регрессии

Рисунок 1 – Созданный сценарий

К файлу "Денежные доходы.xlsx" был применён метод линейной регрессии для оценки среднедушевых доходов на основе входных данных. Параметры компонента Линейная регрессия представлены на рисунках 2–3.

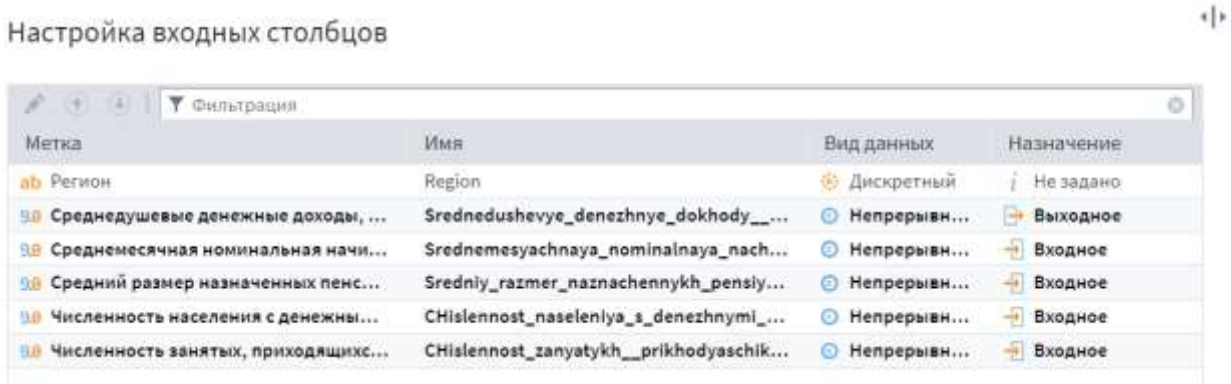

Рисунок 2 – Настройка компонента Линейная регрессия

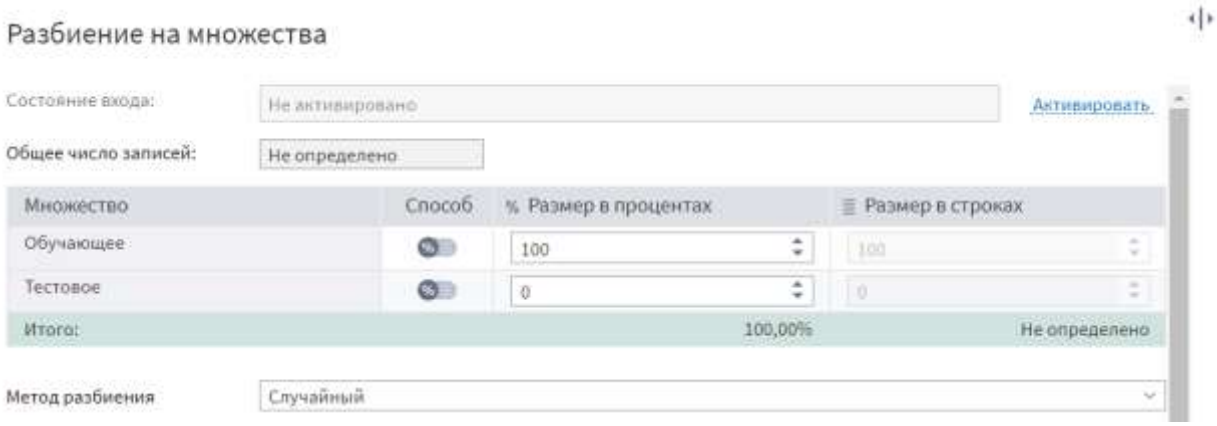

Рисунок 3 – Настройка компонента Линейная регрессия

Сводка о регрессии представлена на рисунке 4. Коэффициент детерминации 0.94, указывает на высокую степень соответствия регрессионной модели исходным данным.

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	14
2	12 TotalSelectedSamples	Всего отобранных примеров	14
3	12 TrainSamples	Примеров в обучающем множестве	14
4	9.0 LogLikelihood	Логарифм функции правдоподобия	-118,22
5	9.0 R2	Коэффициент детерминации	0,94
6	9.0 AdjustedR2	Скорректированный коэффициент детерминации	0,92
7	9.0 StdDev	Стандартное отклонение	1 403,00
8	12 DFE	Число степеней свободы ошибки	9
9	12 ModelDF	Число степеней свободы модели	4
10	9.0 FStatistic	F-статистика	36,56
11	9.0 AIC	Информационный критерий Акаике	17,60
12	9.0 AICc	Информационный критерий Акаике скорректированный	18,14
13	9.0 BIC	Информационный критерий Байеса	17,83
14	9.0 HQC	Информационный критерий Ханнана-Куинна	17,58
15	9.0 ModelPValue	P-значение модели	0,00

Рисунок 4 – Сводка

Также была выполнена оценка регрессии с применением компонента regression metrics, результаты этой оценки отображены на рисунке 5. Эти значения совпадают с теми, что получены при использовании компонента линейной регрессии.

Выходной набор данных

#	ab Метрика	9.0 Значение
1	r2	0,94
2	explained_variance	0,94
3	max_error	1 957,01
4	mean_absolute_error	955,94
5	mean_squared_log_error	0,00
6	mean_squared_error	1 265 408,22
7	median_absolute_error	875,46
8	mean_absolute_percentage_error	0,04
9	d2_absolute_error_score	0,75

Рисунок 5 – Сводка из компонента regression metrics

На рисунке 6 показана диаграмма прогноза относительно фактического значения. По данной диаграмме можно сделать вывод, что прогнозируемое значение можно считать достаточно достоверным.

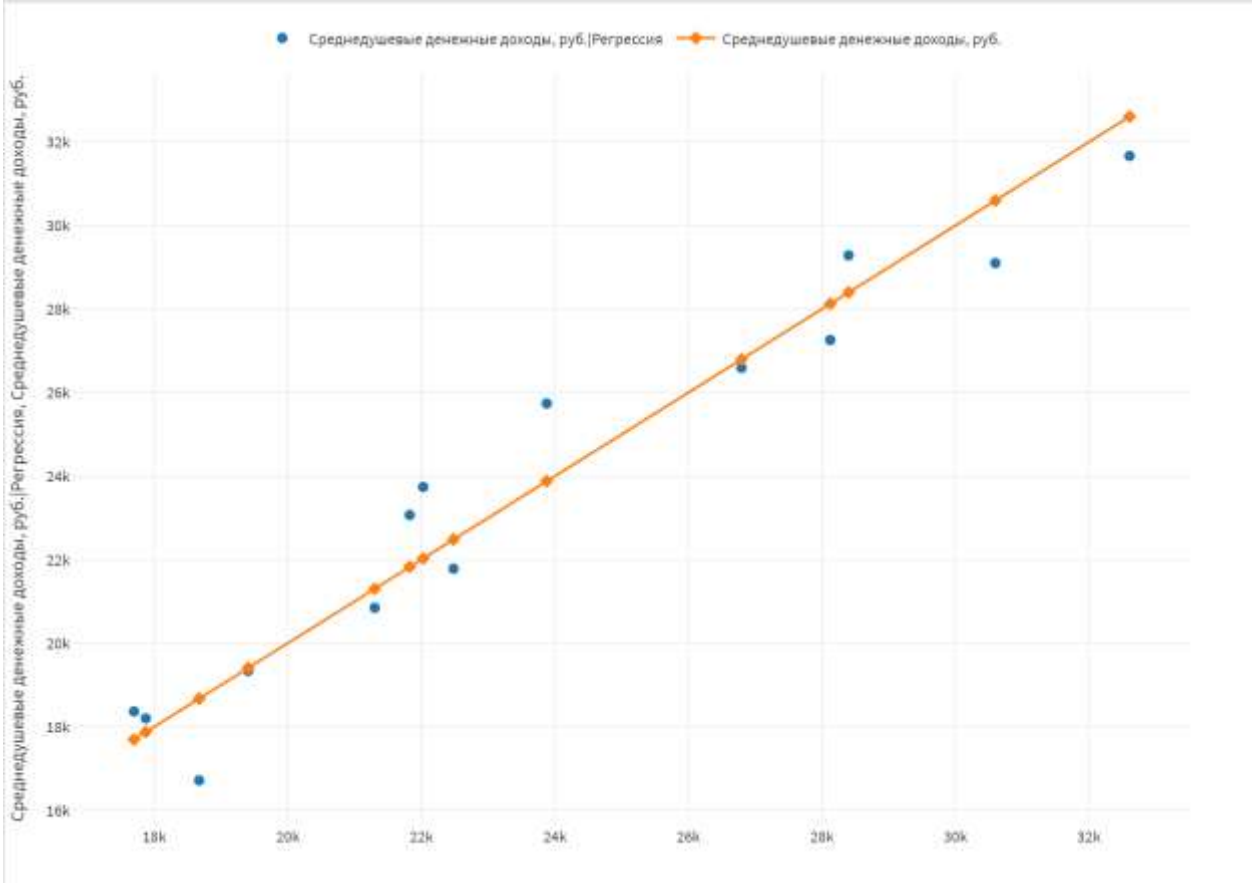

Рисунок 6 – Диаграмма прогноза относительно фактического значения

Рисунок 7 содержит составленный отчёт о регрессии.

На основе полученных коэффициентов из Рисунка 7 была построена математическая модель: $y = -5485{,}720621 + 1{,}125511x_1 + 0{,}601253x_2 - 477{,}9756030x_3 - 1988{,}348844x_4$.

Атрибут	Коэффициент	Стандартная ошибка	Т-статистика	Р-значен...	Нижняя граница ДИ	Верхняя граница ДИ
Среднемесячная номин...	1,125511	0,281488	3,998435	0,003118	0,488741	1,762281
Численность населения...	-477,956030	169,366936	-2,822015	0,019981	-861,090657	-94,821404
Средний размер назнач...	0,601253	1,339360	0,448911	0,664110	-2,428590	3,631097
Численность занятых, п...	-1 988,348844	4 514,853122	-0,440402	0,670034	-12 201,656173	8 224,958485
Константа	-5 485,720621	22 521,237772	-0,243580	0,813018	-56 432,299962	45 460,858720

Рисунок 7 – Отчёт по регрессии

Для данных из файла «Число амбулаторно-поликлинических организаций.xlsx» был разработан сценарий для построения нелинейной регрессии. Были добавлены новые столбцы, содержащие вторую, третью, четвёртую и пятую степени переменной x, с использованием компонента Калькулятор. Затем, с помощью компонента Линейная регрессия, были построены модели нелинейной регрессии. Настройки портов компонента "Линейная регрессия" для этих моделей представлены на рисунках 8–11 соответственно.

Настройка входных столбцов

Фильтрация

Метка	Имя	Вид данных	Назначение
12 Год	God	Непрерывн...	Входное
9.0 Число амбулаторно-поликлиническ...	CHislo_ambulatorno_poliklinicheskikh_...	Непрерывн...	Выходное
9.0 Второй степени	Year2	Непрерывн...	Входное
9.0 Третьей степени	Year3	Непрерывный	Не задано
9.0 Четвёртой степени	Year4	Непрерывный	Не задано
12 № периода	__perioda	Непрерывный	Не задано

Рисунок 8 – Настройка x для нелинейной второй степени

Настройка входных столбцов

Фильтрация

Метка	Имя	Вид данных	Назначение
12 Год	God	Непрерывн...	Входное
9.0 Число амбулаторно-поликлиническ...	CHislo_ambulatorno_poliklinicheskikh_...	Непрерывн...	Выходное
9.0 Второй степени	Year2	Непрерывн...	Входное
9.0 Третьей степени	Year3	Непрерывн...	Входное
9.0 Четвёртой степени	Year4	Непрерывный	Не задано
12 № периода	__perioda	Непрерывный	Не задано

Рисунок 9 – Настройка x для нелинейной третей степени

Настройка входных столбцов

Фильтрация

Метка	Имя	Вид данных	Назначение
12 Год	God	Непрерывн...	Входное
12 № периода	__perioda	Непрерывный	Не задано
9.0 Число амбулаторно-поликлиническ...	CHislo_ambulatorno_poliklinicheskikh_...	Непрерывн...	Выходное
9.0 Второй степени	Year2	Непрерывн...	Входное
9.0 Третьей степени	Year3	Непрерывн...	Входное
9.0 Четвёртой степени	Year4	Непрерывн...	Входное

Рисунок 10 – Настройка x для Нелинейной четвертой степени

Входные	Выходные	Имя	Вид данных	Назначение
12 Год	12 Год	God	Непрерывн...	Входное
12 № периода	12 № периода	__perioda	Непрерывный	Не задано
9.0 Число амбулаторно-поликли...	9.0 Число амбулаторно-поликли...	CHislo_ambulatorno_polikliniche...	Непрерывн...	Выходное
9.0 Второй степени	9.0 Второй степени	Year2	Непрерывн...	Входное
9.0 Третьей степени	9.0 Третьей степени	Year3	Непрерывн...	Входное
9.0 Четвёртой степени	9.0 Четвёртой степени	Year4	Непрерывн...	Входное
9.0 Пятая степень	9.0 Пятая степень	Year5	Непрерывн...	Входное

Рисунок 11 – Настройка x для Нелинейной пятой степени

Сводка полученных регрессий представлено на рисунках 12-15. При увеличении степени коэффициент детерминации также значительно возрастает, следовательно, чем больше степень полинома, тем лучше модель будет соответствовать данным.

Выход регрессии	Коэффициенты регрессионной модели	Сводка	
№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	19
2	12 TotalSelectedSamples	Всего отобранных примеров	19
3	12 TrainSamples	Примеров в обучающем множестве	19
4	9.0 LogLikelihood	Логарифм функции правдоподобия	-32,78
5	9.0 R2	Коэффициент детерминации	0,66
6	9.0 AdjustedR2	Скорректированный коэффициент детерминации	0,62
7	9.0 StdDev	Стандартное отклонение	1,48
8	12 DFE	Число степеней свободы ошибки	16
9	12 ModelDF	Число степеней свободы модели	2
10	9.0 FStatistic	F-статистика	15,55
11	9.0 AIC	Информационный критерий Акаике	3,77
12	9.0 AICc	Информационный критерий Акаике скорректированный	3,85
13	9.0 BIC	Информационный критерий Байеса	3,92
14	9.0 HQC	Информационный критерий Ханнана-Куинна	3,79
15	9.0 ModelPValue	P-значение модели	0,00

Рисунок 12 – Сводка для нелинейной второй степени

Выход регрессии	Коэффициенты регрессионной модели	Сводка	
№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	19
2	12 TotalSelectedSamples	Всего отобранных примеров	19
3	12 TrainSamples	Примеров в обучающем множестве	19
4	9.0 LogLikelihood	Логарифм функции правдоподобия	-28,10
5	9.0 R2	Коэффициент детерминации	0,79
6	9.0 AdjustedR2	Скорректированный коэффициент детерминации	0,75
7	9.0 StdDev	Стандартное отклонение	1,19
8	12 DFE	Число степеней свободы ошибки	15
9	12 ModelDF	Число степеней свободы модели	3
10	9.0 FStatistic	F-статистика	19,10
11	9.0 AIC	Информационный критерий Акаике	3,38
12	9.0 AICc	Информационный критерий Акаике скорректированный	3,53
13	9.0 BIC	Информационный критерий Байеса	3,58
14	9.0 HQC	Информационный критерий Ханнана-Куинна	3,41
15	9.0 ModelPValue	P-значение модели	0,00

Рисунок 13 – Сводка для нелинейной третьей степени

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	19
2	12 TotalSelectedSamples	Всего отобранных примеров	19
3	12 TrainSamples	Примеров в обучающем множестве	19
4	9.0 LogLikelihood	Логарифм функции правдоподобия	-20,30
5	9.0 R2	Коэффициент детерминации	0,91
6	9.0 AdjustedR2	Скорректированный коэффициент детерминации	0,88
7	9.0 StdDev	Стандартное отклонение	0,82
8	12 DFE	Число степеней свободы ошибки	14
9	12 ModelDF	Число степеней свободы модели	4
10	9.0 FStatistic	F-статистика	34,81
11	9.0 AIC	Информационный критерий Акаике	2,66
12	9.0 AICc	Информационный критерий Акаике скорректированный	2,91
13	9.0 BIC	Информационный критерий Байеса	2,91
14	9.0 HQC	Информационный критерий Ханнана-Куинна	2,71
15	9.0 ModelPValue	P-значение модели	3,91e-7

Рисунок 14 – Сводка для нелинейной четвертой степени

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	19
2	12 TotalSelectedSamples	Всего отобранных примеров	19
3	12 TrainSamples	Примеров в обучающем множестве	19
4	9.0 LogLikelihood	Логарифм функции правдоподобия	-19,47
5	9.0 R2	Коэффициент детерминации	0,92
6	9.0 AdjustedR2	Скорректированный коэффициент детерминации	0,88
7	9.0 StdDev	Стандартное отклонение	0,81
8	12 DFE	Число степеней свободы ошибки	13
9	12 ModelDF	Число степеней свободы модели	5
10	9.0 FStatistic	F-статистика	28,48
11	9.0 AIC	Информационный критерий Акаике	2,68
12	9.0 AICc	Информационный критерий Акаике скорректированный	3,05
13	9.0 BIC	Информационный критерий Байеса	2,98
14	9.0 HQC	Информационный критерий Ханнана-Куинна	2,73
15	9.0 ModelPValue	P-значение модели	0,00

Рисунок 15 - Сводка для нелинейной пятой степени

Отчёты по регрессии представлены на рисунках 16 – 19.

Атрибут	Коэффициент	Стандартная ошибка	Т-статистика	Р-значение	Нижняя граница ДИ	Верхняя граница ДИ
9.0 Константа	238 618,556001	51 297,942509	4,651620	0,000266	129 871,775837	347 365,336165
12 Год	-237,341211	51,068403	-4,647516	0,000268	-345,601388	-129,081033
9.0 Второй степени	0,059022	0,012710	4,643771	0,000270	0,032078	0,085966

Рисунок 16 – Отчёт по регрессии для нелинейной второй степени

Атрибут	Коэффициент	Стандартная ошибка	Т-статистика	Р-значение	Нижняя граница ДИ	Верхняя граница ДИ
Константа	-53 831 817,016...	2,494483	-21 580 352,861345	1,307579e-102	-53 831 822,333165	-53 831 811,699437
Год	80 505,690678	5,837956	13 790,047722	1,081083e-54	80 493,247389	80 518,133986
Второй степени	-40,131815	12,894538	-3,112311	0,007135	-67,615872	-12,647759
Третьей степени	0,006668	0,000000	∞	0,000000	0,006668	0,006668

Рисунок 17 – Отчёт по регрессии для нелинейной третьей степени

Атрибут	Коэффициент	Стандартная оши...	Т-статистика	Р-значение	Нижняя граница ДИ	Верхняя граница ДИ
Константа	-21 800 581 222...	1,713389	-12 723 663 360,00...	7,576231e-135	-21 800 581 226,590416	-21 800 581 219,2407
Год	43 379 570,274...	4,009925	10 818 051,124037	7,344076e-92	43 379 561,674382	43 379 578,8752
Второй степени	-32 369,154451	8,856889	-3 654,666906	2,911509e-43	-32 388,150588	-32 350,1583
Третьей степени	10,734767	0,000000	∞	0,000000	10,734767	10,7347
Четвёртой степени	-0,001335	58 278 617 344 896,1...	-2,290728e-17	1,000000	-124 995 202 671 593,140...	124 995 202 671 593,1400

Рисунок 18 – Отчёт по регрессии для нелинейной четвертой степени

Атрибут	Коэффициент	Стандартная ошибка	Т-статистика	Р-значение	Нижняя граница ДИ	Верхняя граница ДИ
Константа	2 409 942 296 6...	1,701423	1 416 427 591 105,402000	4,090059e-152	2 409 942 296 681,617000	2 409 942 296 688,968800
Год	-6 008 783 093,...	3,981920	-1 509 016 356,805843	1,795706e-113	-6 008 783 102,172480	-6 008 783 084,967648
Второй степени	5 992 705,971254	8,795019	681 374,989194	5,536510e-70	5 992 686,970771	5 992 724,971738
Третьей степени	-2 988,312350	0,000000	∞	0,000000	-2 988,312350	-2 988,312350
Четвёртой степени	0,745067	57 871 615 153 539,766...	1,287449e-14	1,000000	-125 024 023 476 583,690000	125 024 023 476 585,190000
Пятая степень	-0,000074	116 271 419 465 007 40...	-6,390705e-22	1,000000	-251 189 130 254 639 700,00...	251 189 130 254 639 700,000...

Рисунок 19 – Отчёт по регрессии для нелинейной пятой степени

Диаграммы прогноза по годам для нелинейной регрессии представлены на рисунках 20 – 23. По ним также можно увидеть, что чем выше степень для нелинейной модели, тем более точным становится прогноз.

По полученным коэффициентам была построена математическая модель для нелинейной модели

2 степени: $y = 0{,}059022x^2 – 237{,}341211x + 238\,618{,}556\,001$

3 степени: $y = 0{,}006668x^3 – 40{,}131815x^2 + 80\,505{,}690678x – 53\,831\,817{,}016$

4 степени: $y = - 0{,}001335x^4 + 10{,}734767x^3 - 32369{,}154451x^2 + 43\,379\,570{,}240x - 53\,831\,817{,}015$

5 степени: $y = - 0{,}000074x^5 + 0{,}745067x^4 - 2\,988{,}312350x^3 + 5\,992\,705{,}971254x^2 – 6\,008\,783\,093{,}570064x + 2\,409\,942\,296\,685{,}293000$

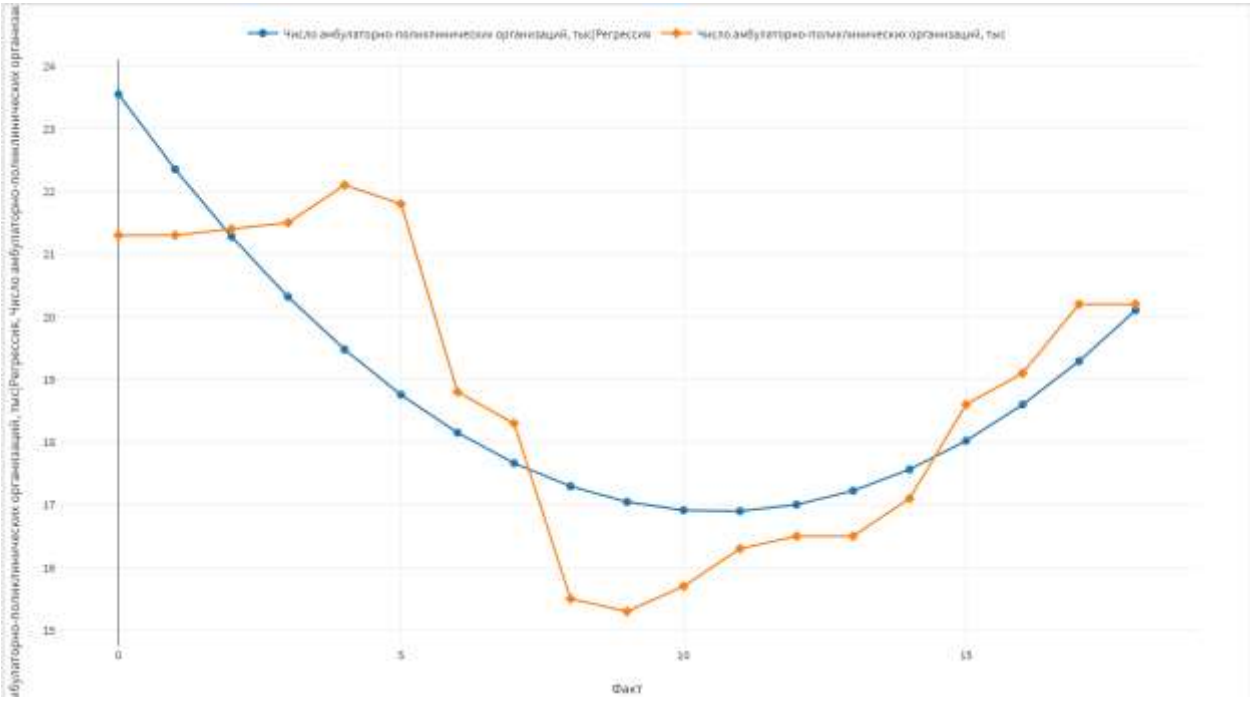

Рисунок 20 – Диаграмма прогноза по годам для нелинейной второй степени

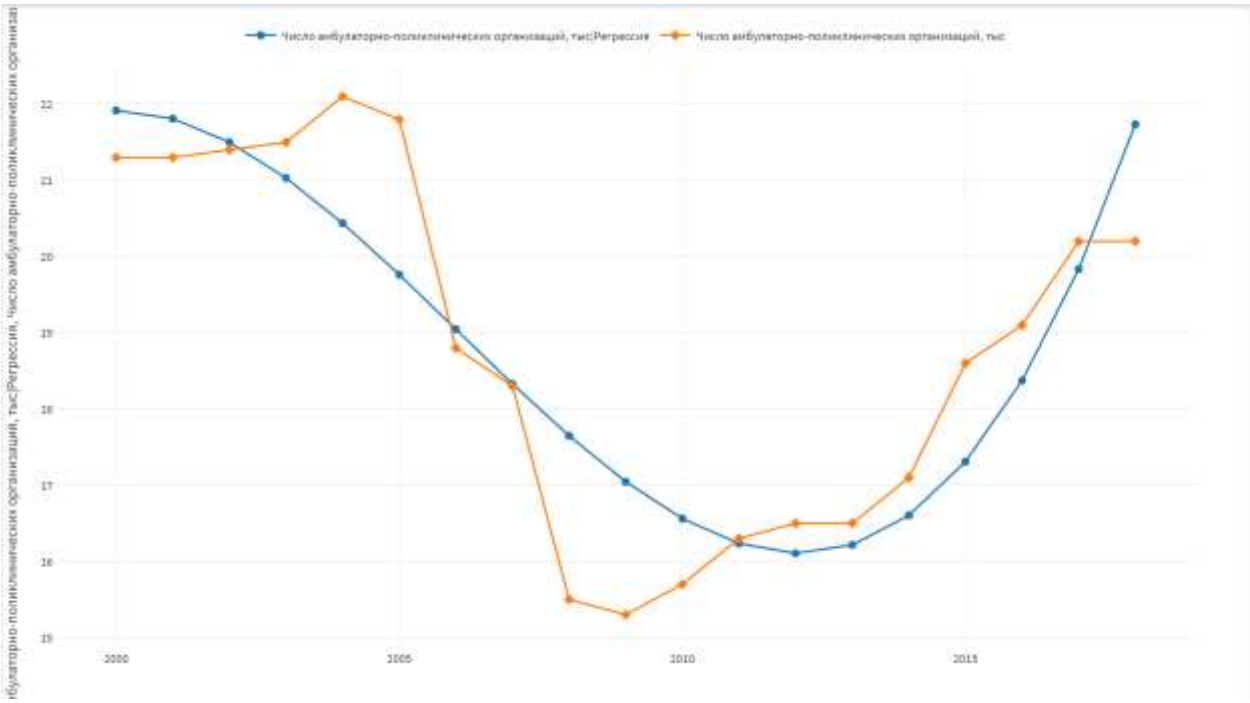

Рисунок 21 – Диаграмма прогноза по годам для нелинейной третьей степени

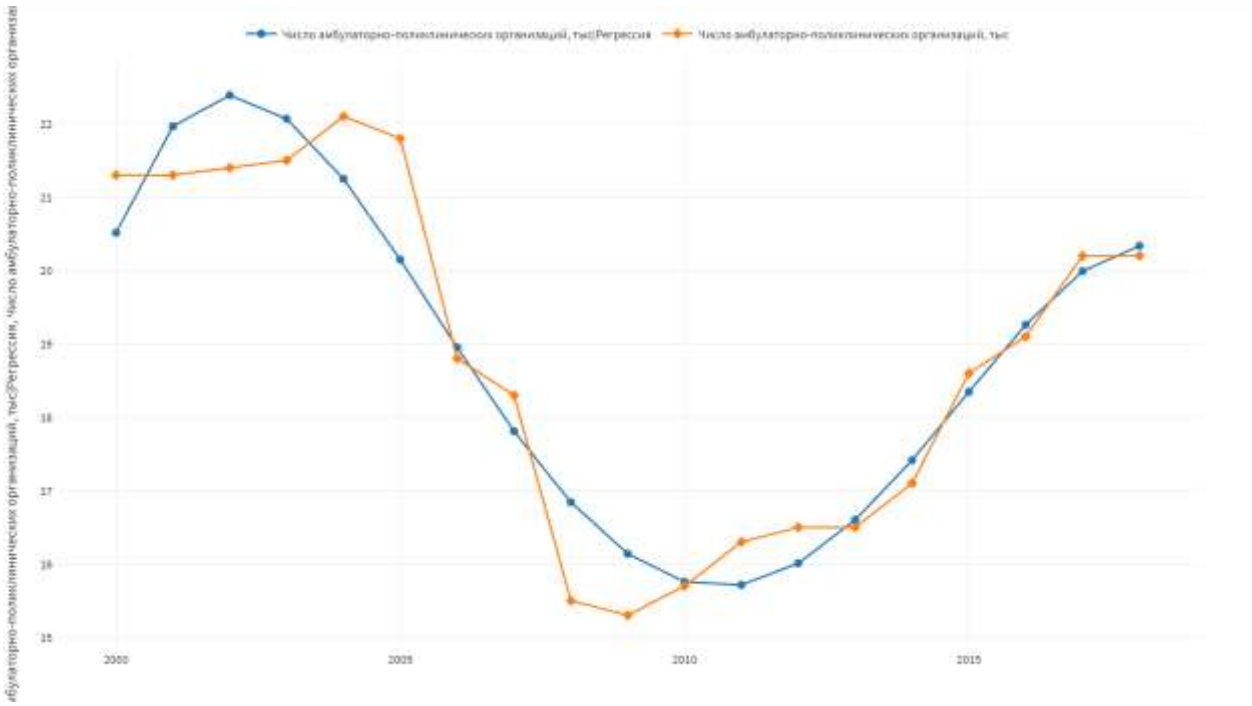

Рисунок 22 – Диаграмма прогноза по годам для нелинейной четвертой степени

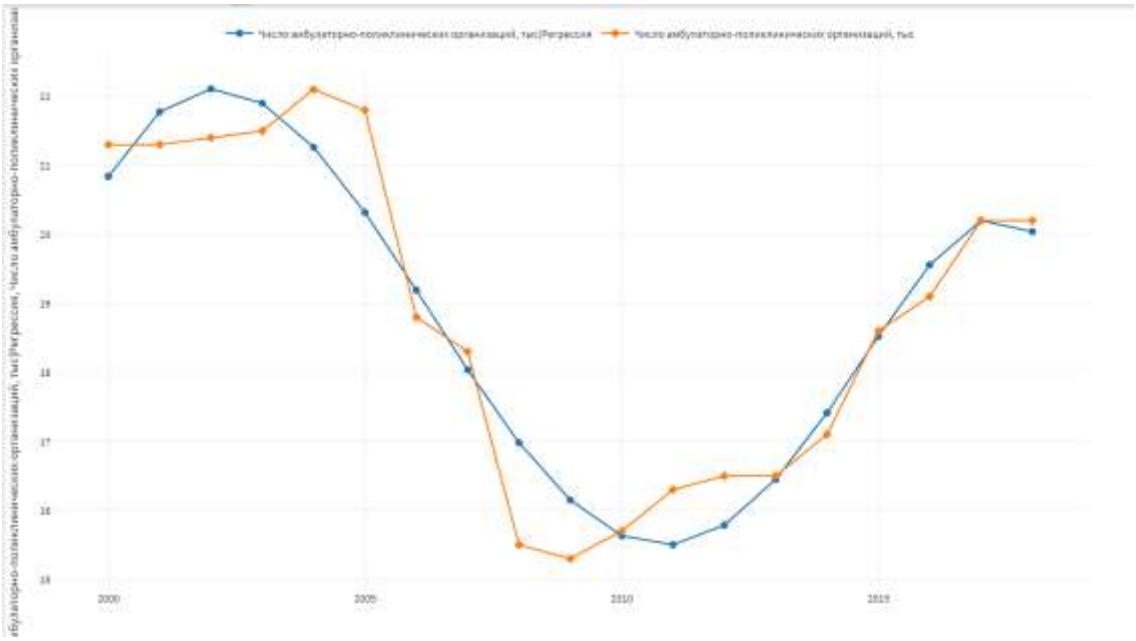

Рисунок 23 – Диаграмма прогноза по годам для нелинейной пятой степени

Для данных из файла «Клиенты торговой сети.xlsx» был использован компонент Логистическая регрессия для оценки склонности клиентов к приобретению продуктов новой линии.

Поскольку Логистическая регрессия не может обрабатывать неполные данные, для корректного заполнения недостающей информации был проведен анализ через визуализатор Куб зависимостей одних значений полей от других. Проведенный анализ показан на рисунках 24-28.

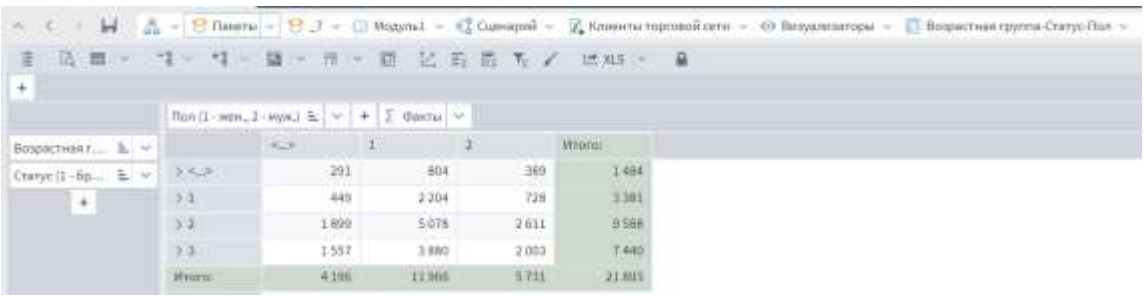

Возрастная г... / Статус (1 - бр...	<...>	1	2	Итого:
> <...>	291	804	389	1 484
> 1	449	2 204	728	3 381
> 2	1 899	5 078	2 611	9 588
> 3	1 557	3 880	2 003	7 440
Итого:	4 196	11 966	5 731	21 893

Рисунок 24 – Анализ данных для дальнейшего заполнения

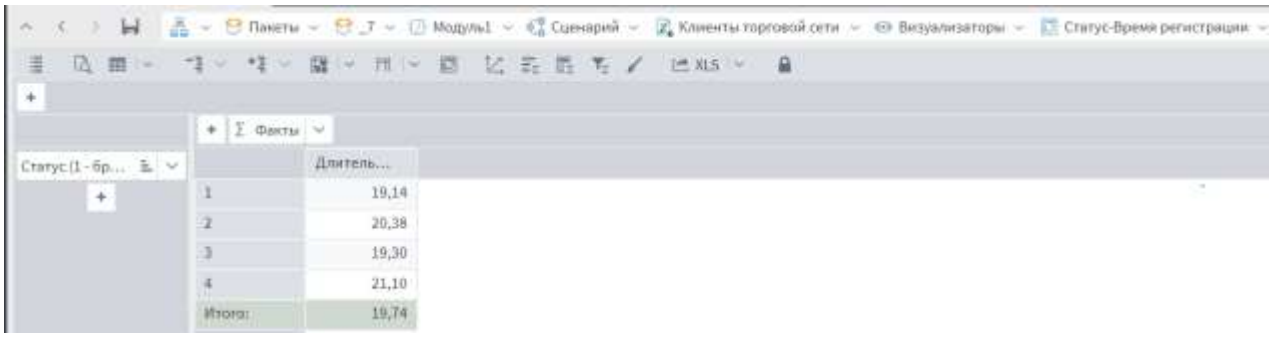

Статус (1 - бр...	Длитель...
1	19,14
2	20,38
3	19,30
4	21,10
Итого:	19,74

Рисунок 25 – Анализ данных для дальнейшего заполнения

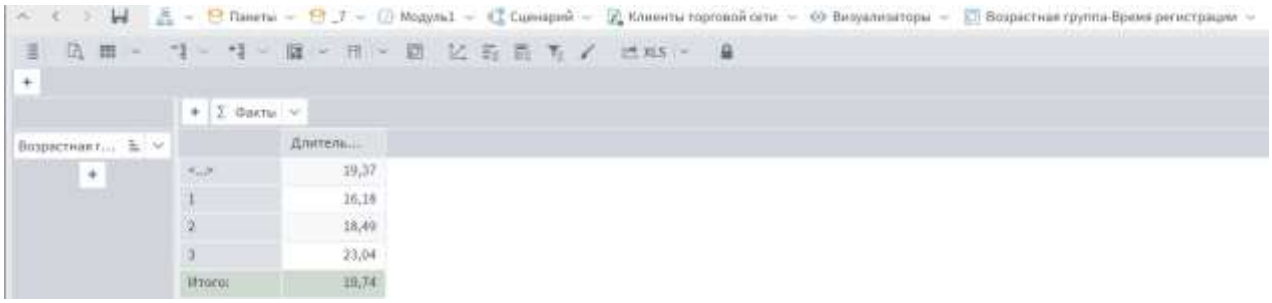

Возрастная г...	Длитель...
<...>	19,37
1	16,18
2	18,49
3	23,04
Итого:	19,74

Рисунок 26 – Анализ данных для дальнейшего заполнения

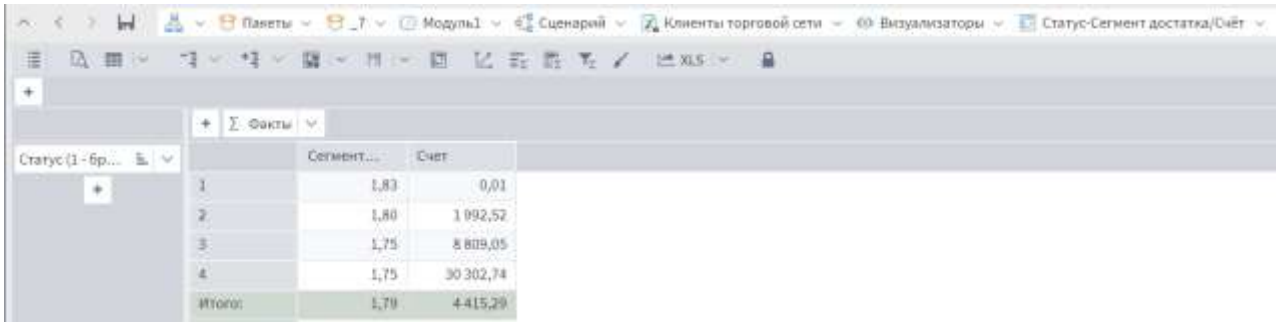

Статус (1 - бр...	Сегмент...	Счет
1	1,83	0,01
2	1,80	1 992,52
3	1,75	8 809,05
4	1,75	30 302,74
Итого:	1,79	4 415,29

Рисунок 27 – Анализ данных для дальнейшего заполнения

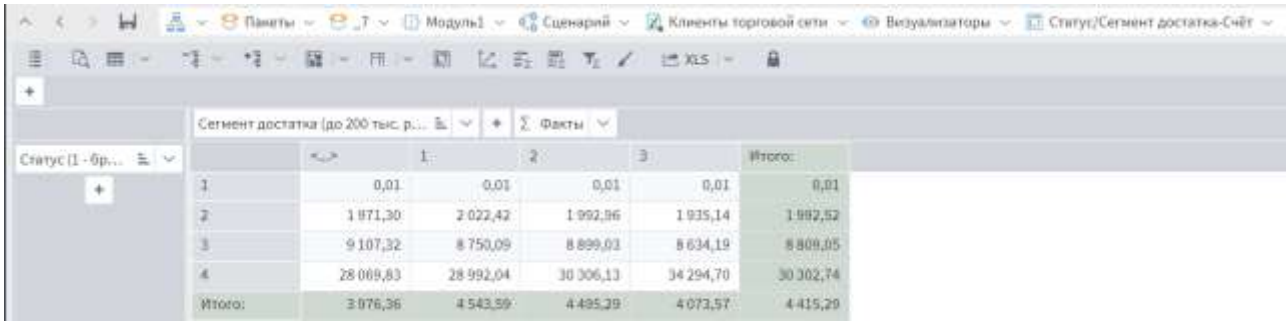

Статус (1 - бр... / Сегмент достатка (до 200 тыс. р...	<...>	1	2	3	Итого:
1	0,01	0,01	0,01	0,01	0,01
2	1 971,30	2 022,42	1 992,96	1 935,14	1 992,52
3	9 107,32	8 750,09	8 899,03	8 634,19	8 809,05
4	28 069,83	28 992,04	30 306,13	34 294,70	30 302,74
Итого:	3 976,36	4 543,59	4 495,29	4 073,57	4 415,29

Рисунок 28 – Анализ данных для дальнейшего заполнения

Для заполнения недостающей информации был применен компонент Калькулятор, настройка которого показана на рисунках 29–35.

Пропуски в строках были заполнены на основе имеющегося набора данных. Кроме того, было добавлено дополнительное логическое поле, отражающее факт совершения покупки.

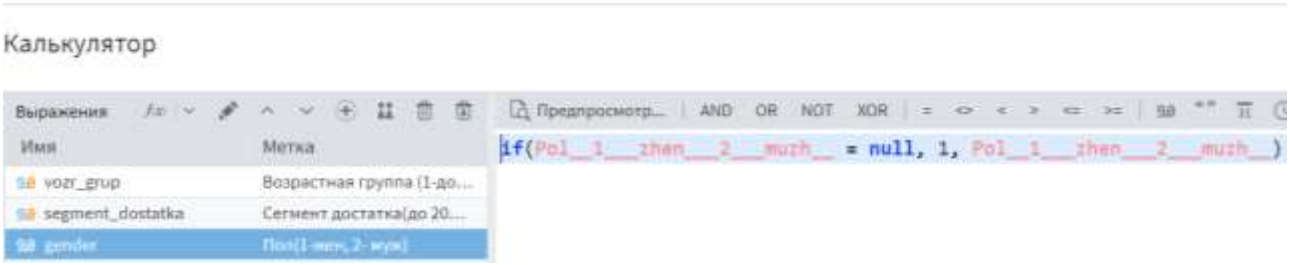

Рисунок 29 – Выражение в калькуляторе для поля Пол

Рисунок 30 – Выражение в калькуляторе для поля Возрастная группа

Рисунок 31 – Выражение в калькуляторе для поля Статус

Рисунок 32 – Выражение в калькуляторе для поля Сегмент достатка

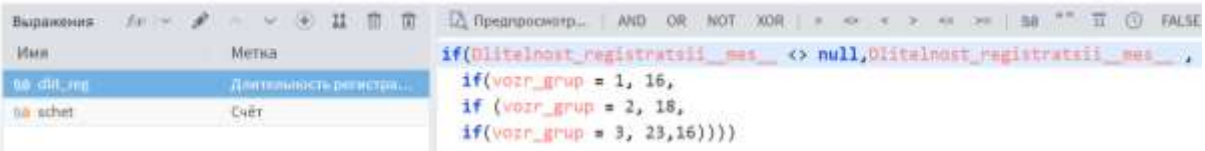

Рисунок 33 – Выражение в калькуляторе для поля Длительность регистрации

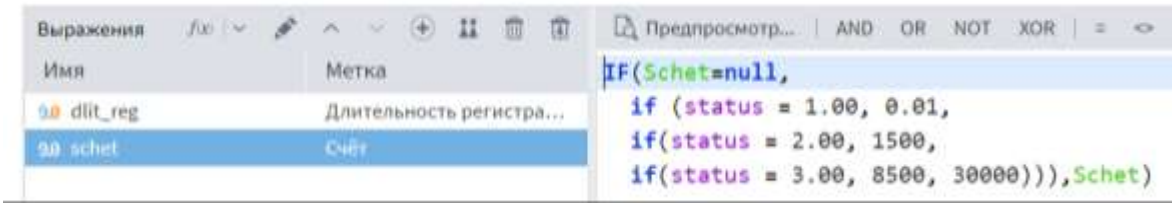

Рисунок 34 – Выражение в калькуляторе для поля Счет

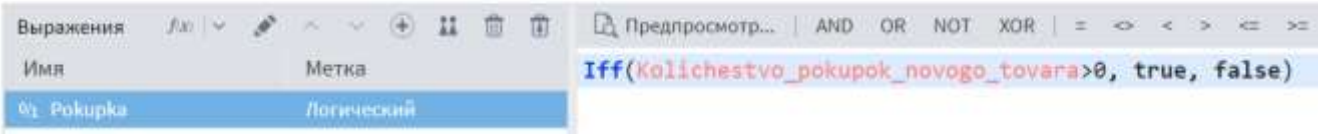

Рисунок 35 – Выражение в калькуляторе для логического поля о покупке

Настройка компонента Логистическая регрессия представлена на рисунках 36–37.

Рисунок 36 – Настройка компонента Логистическая регрессия

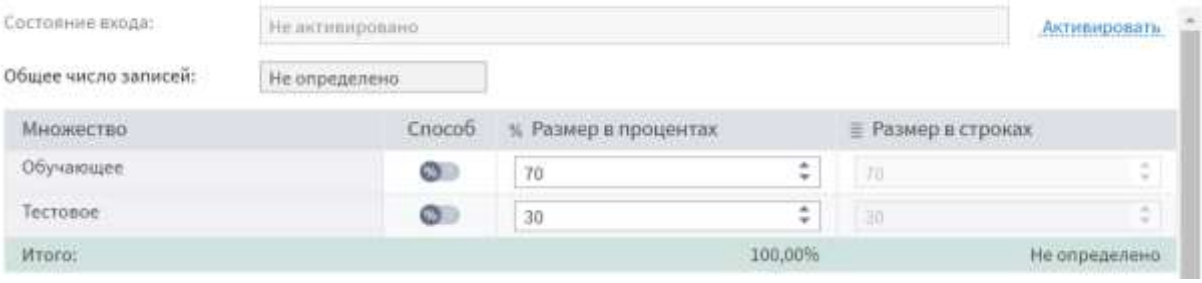

Рисунок 37 – Настройка компонента Логистическая регрессия

Сводка полученной регрессии представлена на рисунке 38.

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	TotalSamples	Всего примеров	21 893
2	TotalSelectedSamples	Всего отобранных примеров	21 893
3	TrainSamples	Примеров в обучающем множестве	15 325
4	TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,39
5	TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	20,27
6	TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,20
7	TrainThreshold	Порог отсечения при обучении модели	0,50
8	NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	5 007,62
9	MinusTwoLogL	-2 Логарифма функции правдоподобия	4 196,33
10	R2	Псевдо-R^2 Макфаддена	0,16
11	AdjustedR2	Псевдо-R^2 Макфаддена (скорр.)	0,16
12	DFE	Число степеней свободы ошибки	15 318
13	ModelDF	Число степеней свободы модели	6
14	Chi2	Хи-квадрат	811,29
15	AIC	Информационный критерий Акаике	0,27
16	AICc	Информационный критерий Акаике скорректированный	0,27
17	BIC	Информационный критерий Байеса	0,28
18	HQC	Информационный критерий Ханнана-Куинна	0,28
19	ModelPValue	P-значение модели	5,58e-172
20	TestSamples	Примеров в тестовом множестве	6 568
21	TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,38
22	TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	20,45
23	TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,67

Рисунок 38 – Сводка

На рисунке 39 представлен отчёт о качестве бинарной классификации с ROC-кривой.

Отчёт по регрессии представлен на рисунке 40.

По полученным коэффициентам была построена математическая модель: $y = -0{,}009396 - 0{,}793808*x_1 - 0{,}937871*x_2 - 0{,}101189*x_3 + 0{,}000083*x_4 + 0{,}000001*x_5 + 1{,}069333*x_6$.

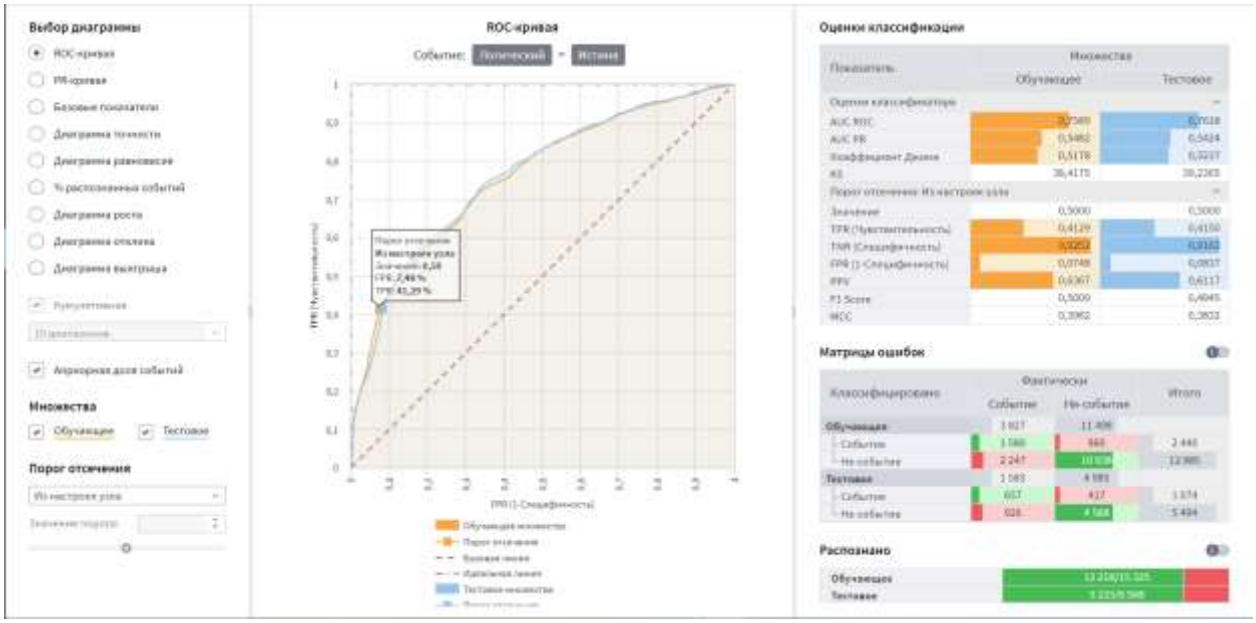

Рисунок 39 – Качество бинарной классификации

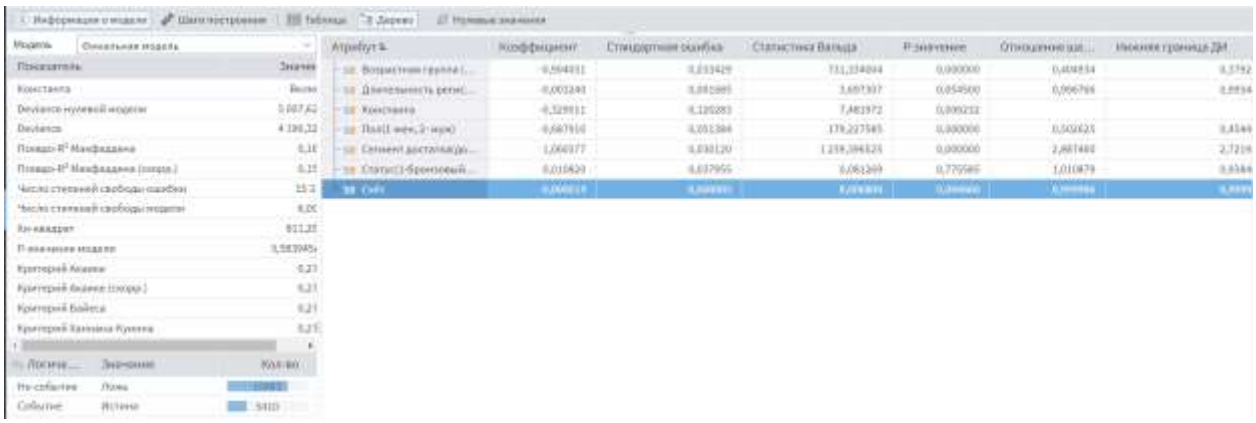

Рисунок 40 – Качество бинарной классификации

Вывод

В ходе лабораторной работы были выполнены три задания для трех различных наборов данных:

Для файла Денежные доходы.xlsx была установлена зависимость среднедушевых доходов от отобранных факторов.

Для файла Число амбулаторно-поликлинических организаций.xlsx было промоделировано временное изменение числа амбулаторно поликлинических организаций.

Для файла Клиенты торговой сети.xlsx, используя 70% случайную выборку клиентов, была создана модель для оценки склонности клиентов к приобретению продуктов новой линии. Выбросы и экстремальные значения были оставлены без изменения.