ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук		Н.В. Богословская
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №8

БИННИНГ ДАННЫХ

по курсу: БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №	4127		А. А. Костина
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2024

1 Задание

Создать модель биннинга для набора otp_train.lgd и выполнить логистическую регрессию с учетом вычисленных IV-индексов. Научиться лучше редактировать процесс биннинга непосредственно в узле Конечные классы.

2 Результаты проделанной работы

На рисунке 1 представлен созданный сценарий.

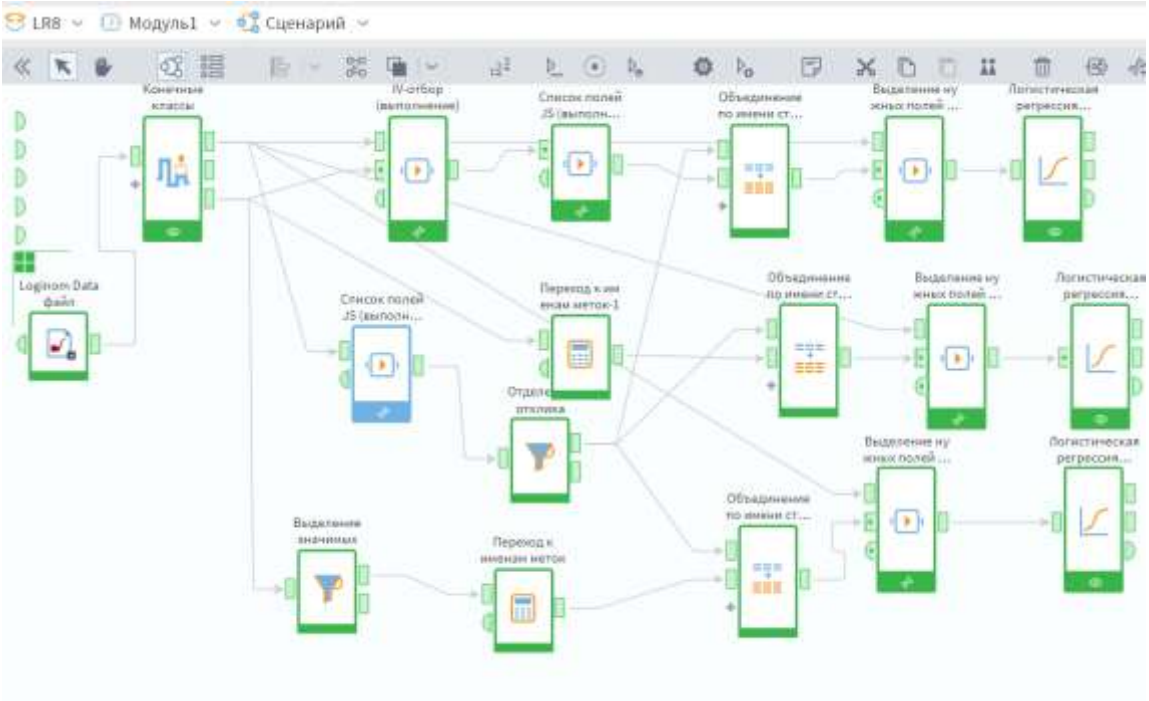

Рисунок 1 – Созданный сценарий

С помощью компонента Конечные классы данные из файла otp_train.lgd были преобразованы в интервалы значений. На рисунках 2-3 приведены изменения процента значимости входных параметров. На рисунке 5 представлены параметры классов, а на рисунке 6 значимость столбцов.

Рисунок 2 – Пример изменения процента значимости входных параметров

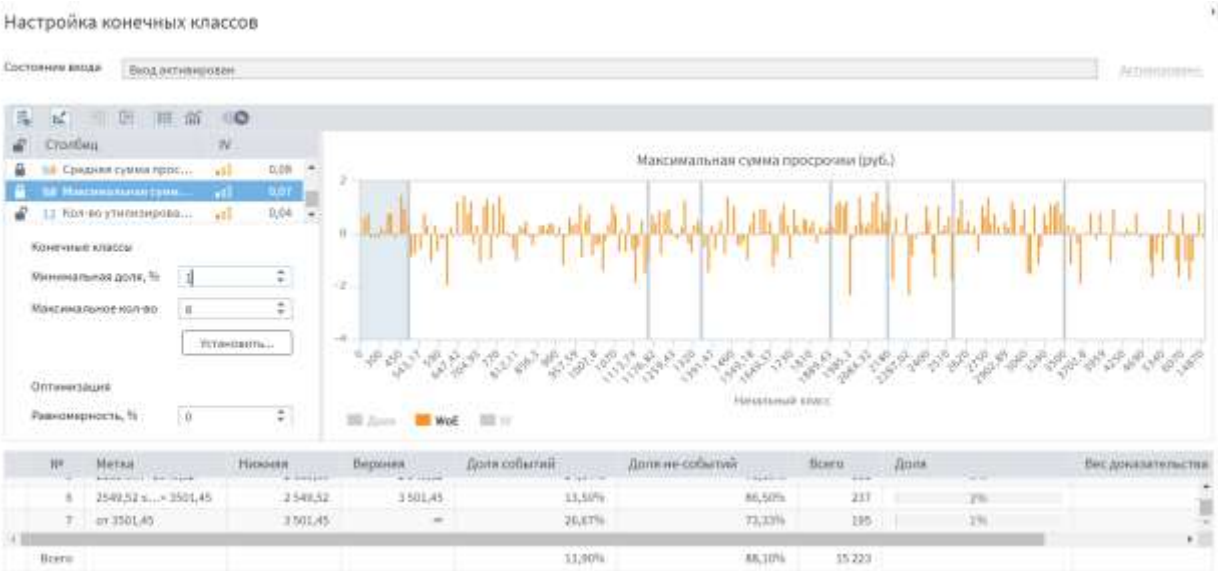

Рисунок 3 – Пример изменения процента значимости входных параметров

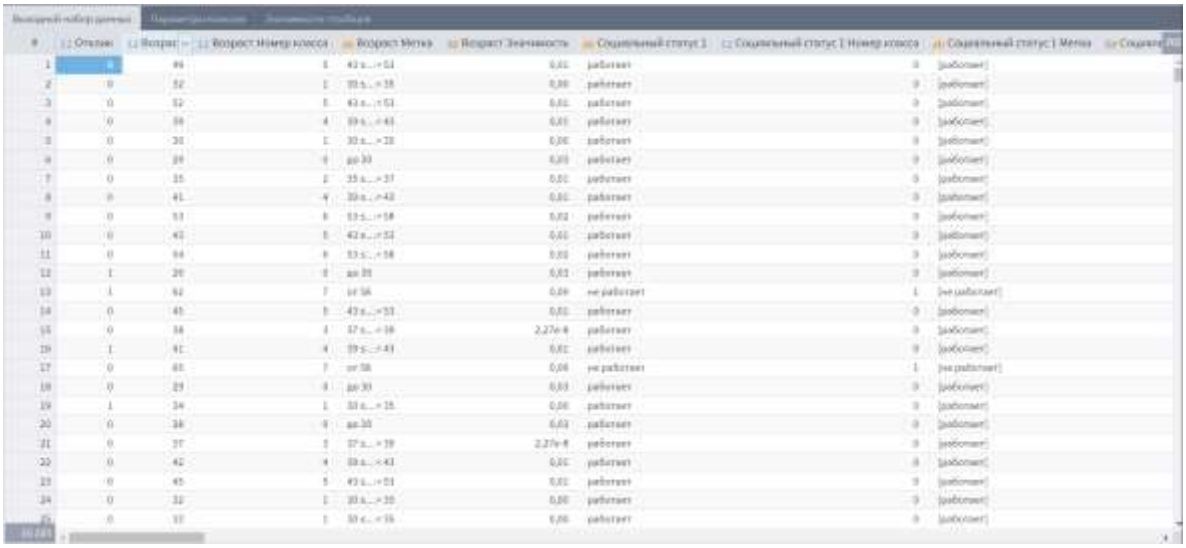

Рисунок 4 – Результат работы компонента Конечные классы

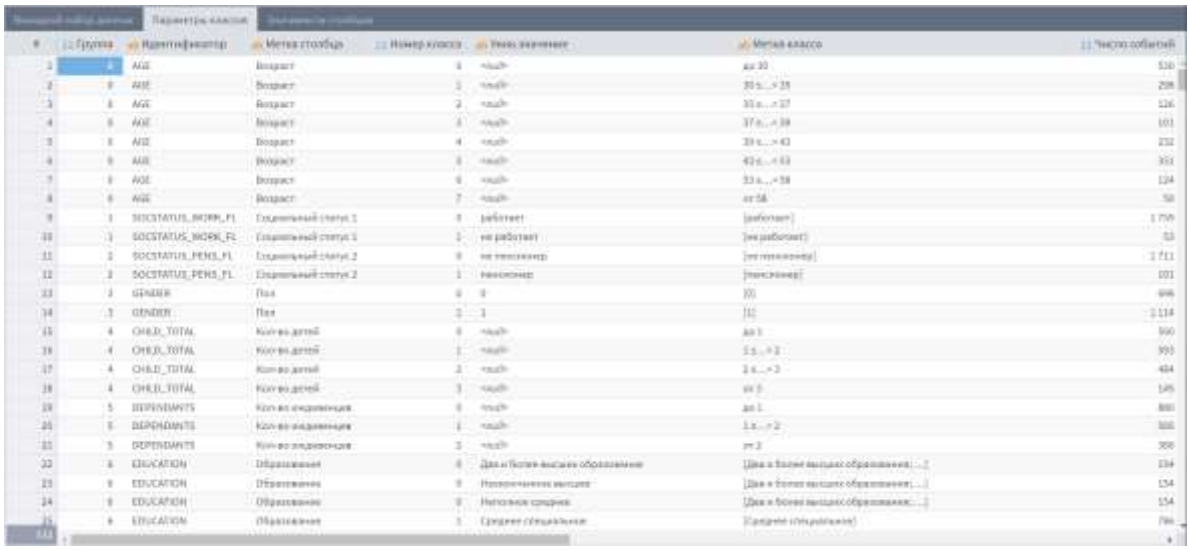

Рисунок 5 – Параметры классов

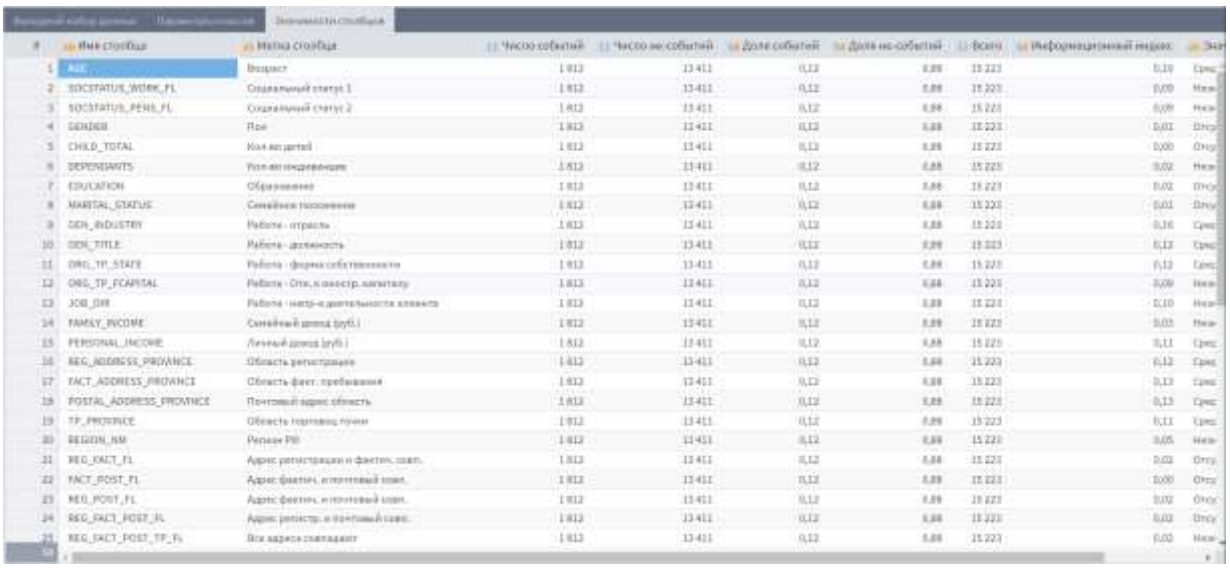

Рисунок 6 – Значимости столбцов

Для отбора значимых столбцов был использован компонент IV-отбор. На рисунке 7 изображен результат работы компонента.

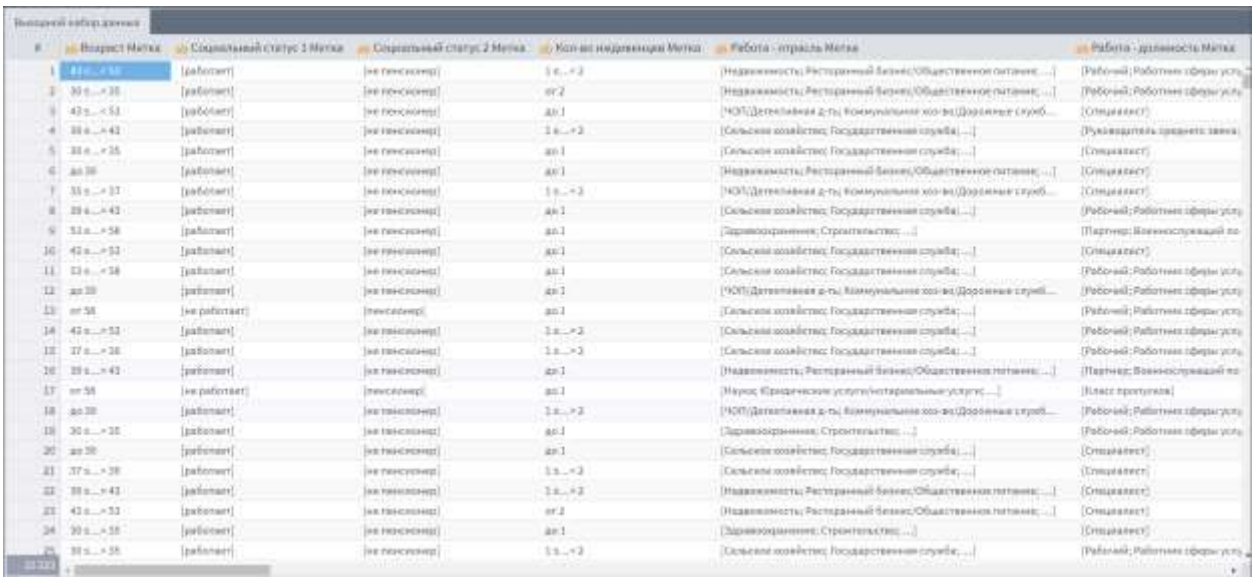

Рисунок 7 – Результат работы компонента IV-отбор

Чтобы выделить значимые столбцы для дальнейшего анализа был использован Фильтр строк, убирающий входные данные с отсутствующей и низкой значимостью. На рисунке 8 изображены настройка компонента Фильтр строк и результат его работы.

Фильтрация данных

Состояние входа | Вход активирован | Активировано

ab Значимость столбца <> Низкая × | И | ab Значимость столбца <> Отсутствует × | +

#	Значим...	Имя ст...	Метка с...	Число с...	Число ...	Доля с...	Доля н...	Всего
1	Средняя	AGE	Возраст	1 812	13 411	0,12	0,88	15 223
2	Средняя	GEN_INDU...	Работа - о...	1 812	13 411	0,12	0,88	15 223
3	Средняя	GEN_TITLE	Работа - д...	1 812	13 411	0,12	0,88	15 223
4	Средняя	ORG_TP_S...	Работа - ф...	1 812	13 411	0,12	0,88	15 223
5	Средняя	PERSONA...	Личный д...	1 812	13 411	0,12	0,88	15 223
6	Средняя	REG_ADD...	Область р...	1 812	13 411	0,12	0,88	15 223
7	Средняя	FACT_ADD...	Область ...	1 812	13 411	0,12	0,88	15 223
8	Средняя	POSTAL_A...	Почтовый...	1 812	13 411	0,12	0,88	15 223
9	Средняя	TP_PROVI...	Область т...	1 812	13 411	0,12	0,88	15 223
10	Средняя	WORK_TIME	Стаж рабо...	1 812	13 411	0,12	0,88	15 223

Рисунок 8 – Настройка компонента Фильтр строк представлена и результат его работы

Для перехода от названия входных параметров к именам меток входных параметров был применен компонент Калькулятор, настройка которого представлена на рисунке 9, а результат работы на рисунке 10.

Выражения | f(x) | Предпросмотр... | AND | O

Имя	Метка
ab Metka	Метка

```
ColumnName+"_ClassMark"
```

Рисунок 9 – Настройка компонента Калькулятор

Рисунок 10 – Результат работы компонента Калькулятор

Для выделения отклика из входных параметров, необходимого для проведения логистической регрессии был использован Список полей JS. На рисунке 11 представлен результат работы компонента.

Выходной набор данных

#	ab Поле.Имя	ab Поле.Метка	ab Поле.Тип	ab Поле.Вид
1	TARGET	Отклик	Integer	Discrete
2	AGE	Возраст	Integer	Continuous
3	AGE_ClassNum	Возраст Номер класса	Integer	Discrete
4	AGE_ClassMark	Возраст Метка	String	Discrete
5	AGE_ClassSignificant	Возраст Значимость	Float	Continuous
6	SOCSTATUS_WORK_FL	Социальный статус 1	String	Discrete
7	SOCSTATUS_WORK_FL_ClassNum	Социальный статус 1 Номер класса	Integer	Discrete
8	SOCSTATUS_WORK_FL_ClassMark	Социальный статус 1 Метка	String	Discrete
9	SOCSTATUS_WORK_FL_ClassSignificant	Социальный статус 1 Значимость	Float	Continuous
10	SOCSTATUS_PENS_FL	Социальный статус 2	String	Discrete
11	SOCSTATUS_PENS_FL_ClassNum	Социальный статус 2 Номер класса	Integer	Discrete
12	SOCSTATUS_PENS_FL_ClassMark	Социальный статус 2 Метка	String	Discrete
13	SOCSTATUS_PENS_FL_ClassSignificant	Социальный статус 2 Значимость	Float	Continuous
14	GENDER	Пол	Integer	Discrete
15	GENDER_ClassNum	Пол Номер класса	Integer	Discrete
16	GENDER_ClassMark	Пол Метка	String	Discrete
17	GENDER_ClassSignificant	Пол Значимость	Float	Continuous
18	CHILD_TOTAL	Кол-во детей	Integer	Continuous
19	CHILD_TOTAL_ClassNum	Кол-во детей Номер класса	Integer	Discrete
20	CHILD_TOTAL_ClassMark	Кол-во детей Метка	String	Discrete
21	CHILD_TOTAL_ClassSignificant	Кол-во детей Значимость	Float	Continuous
22	DEPENDANTS	Кол-во иждивенцев	Integer	Continuous
23	DEPENDANTS_ClassNum	Кол-во иждивенцев Номер класса	Integer	Discrete
24	DEPENDANTS_ClassMark	Кол-во иждивенцев Метка	String	Discrete
25	DEPENDANTS_ClassSignificant	Кол-во иждивенцев Значимость	Float	Continuous
202	EDUCATION	Образование	String	Discrete

Рисунок 11 – Результат работы компонента Фильтр JS

Далее при помощи компонента Фильтр строк было осуществлено отделение отклика. На рисунке 12 изображены настройка компонента Фильтр строк и результат его работы.

Фильтрация данных

Состояние входа: Вход активирован

ab Поле.Метка = Отклик

#	ab Поле.М...	ab Поле.Имя	ab Поле.Тип	ab Поле.Вид
1	Отклик	TARGET	Integer	Discrete

Рисунок 12 – Настройка компонента

Был применен компонент Объединение для объединения по имени столбца. На рисунке 13 изображен результат его работы.

Выходной набор данных

#	ab Поле.Имя
1	TARGET
2	AGE_ClassMark
3	GEN_INDUSTRY_ClassMark
4	GEN_TITLE_ClassMark
5	ORG_TP_STATE_ClassMark
6	PERSONAL_INCOME_ClassMark
7	REG_ADDRESS_PROVINCE_ClassMark
8	FACT_ADDRESS_PROVINCE_ClassMark
9	POSTAL_ADDRESS_PROVINCE_ClassMark
10	TP_PROVINCE_ClassMark
11	WORK_TIME_ClassMark

Рисунок 13 – Результат работы компонента Объединение

Для выделения нужных полей с данными был использован компонент Фильтр столбцов JS. На рисунке 14 представлена его настройка, а на рисунке 15 результат работы компонента.

Настройка соответствия между столбцами

Таблица Связи

Фильтрация

Входные	Выходные	Имя	Вид данных	Назначение
Поле.Имя	**Имена столбцов**	**Names**	**Дискретный**	**Используемое**
Поле.Метка	Поле.Метка	FieldLabel	Дискретный	Не задано
Поле.Тип	Поле.Тип	FieldDataType	Дискретный	Не задано
Поле.Вид	Поле.Вид	FieldDataKind	Дискретный	Не задано
Имя столбца	Имя столбца	ColumnName	Дискретный	Не задано
Значимость столбца	Значимость столбца	Significance	Дискретный	Не задано
Метка столбца	Метка столбца	ColumnDisplayName	Дискретный	Не задано
Число событий	Число событий	EventsCount	Непрерывный	Не задано
Число не-событий	Число не-событий	NonEventsCount	Непрерывный	Не задано
Доля событий	Доля событий	EventRate	Непрерывный	Не задано
Доля не-событий	Доля не-событий	NonEventRate	Непрерывный	Не задано
Всего	Всего	TotalEventsCount	Непрерывный	Не задано
Информационный ...	Информационный ...	IV	Непрерывный	Не задано

Рисунок 14 – Настройка компонента

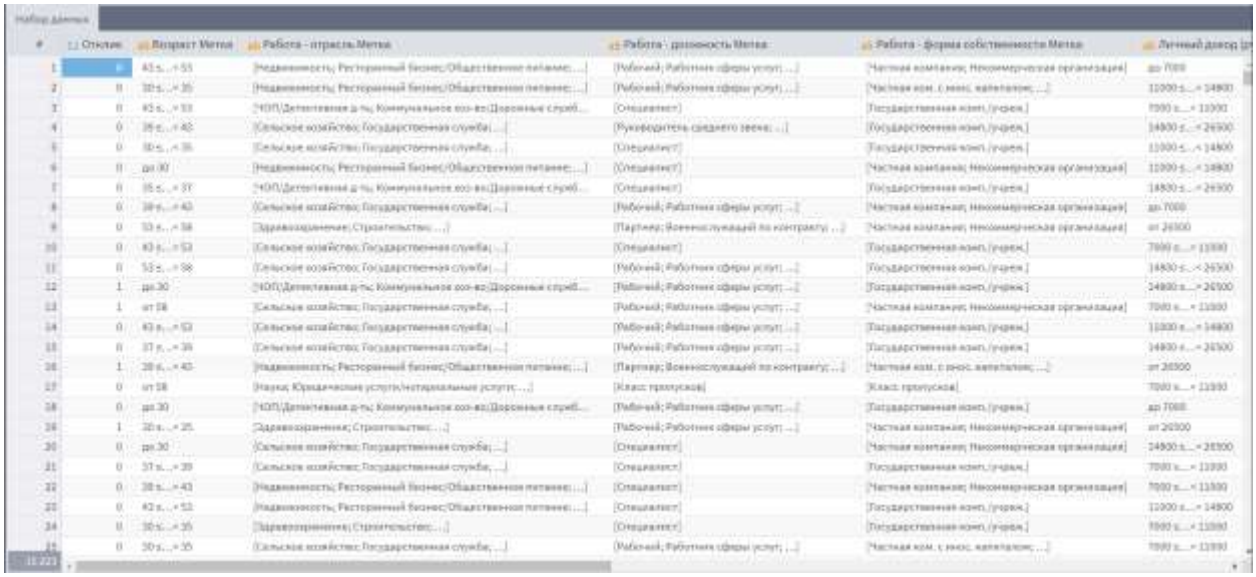

Рисунок 15 – Результат работы компонента Фильтр столбцов JS

Для настроенного набора данных была использована Логистическая регрессия. На рисунке 16 показана настройка порта, на рисунках 17-18 настройка компонента, а на рисунках 19-21 выходные данные. На рисунке 22 изображена полученная ROC-кривая, а на рисунке 23 отчет по логистической регрессии.

Настройка входных столбцов

Фильтрация

Метка	Имя	Вид данных	Назначение
Возраст Метка	AGE_ClassMark	Дискретный	Входное
Работа - отрасль Метка	GEN_INDUSTRY_ClassMark	Дискретный	Входное
Работа - должность Метка	GEN_TITLE_ClassMark	Дискретный	Входное
Работа - форма собственности Метка	ORG_TP_STATE_ClassMark	Дискретный	Входное
Личный доход (руб.) Метка	PERSONAL_INCOME_ClassMark	Дискретный	Входное
Область регистрации Метка	REG_ADDRESS_PROVINCE_ClassMark	Дискретный	Входное
Область факт. пребывания Метка	FACT_ADDRESS_PROVINCE_ClassMark	Дискретный	Входное
Почтовый адрес область Метка	POSTAL_ADDRESS_PROVINCE_ClassMark	Дискретный	Входное
Область торговоц точки Метка	TP_PROVINCE_ClassMark	Дискретный	Входное
Стаж работы на посл. месте (мес.) М...	WORK_TIME_ClassMark	Дискретный	Входное
Отклик	TARGET	Дискретный	Выходное

Рисунок 16 – Настройка порта

Разбиение на множества

Состояние входа: Не активировано Активировать

Общее число записей: Не определено

Множество	Способ	% Размер в процентах	Размер в строках
Обучающее		70	70
Тестовое		30	30
Итого:		100,00%	Не определено

Метод разбиения: Случайный

Параметры метода

Нет настраиваемых параметров

Метод валидации: Без валидации

Параметры валидационного разбиения

Нет настраиваемых параметров

Рисунок 17 – Настройка компонента

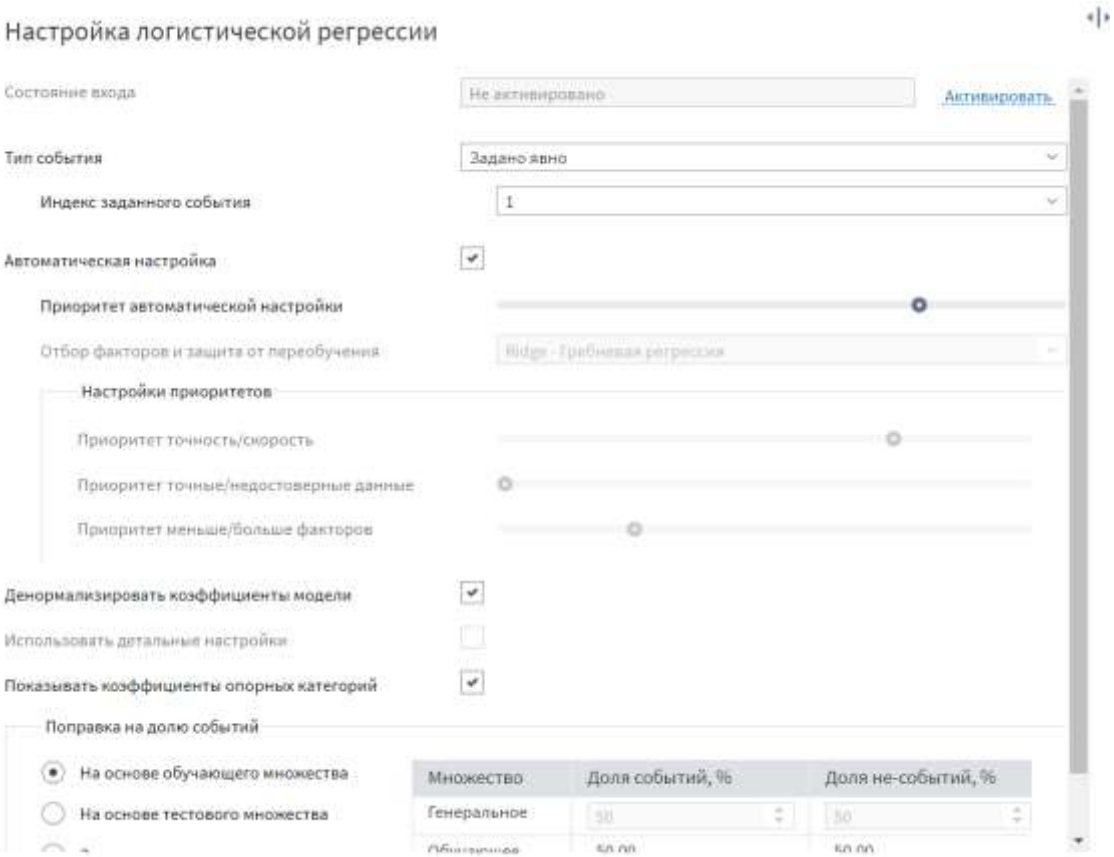

Рисунок 18 – Настройка компонента

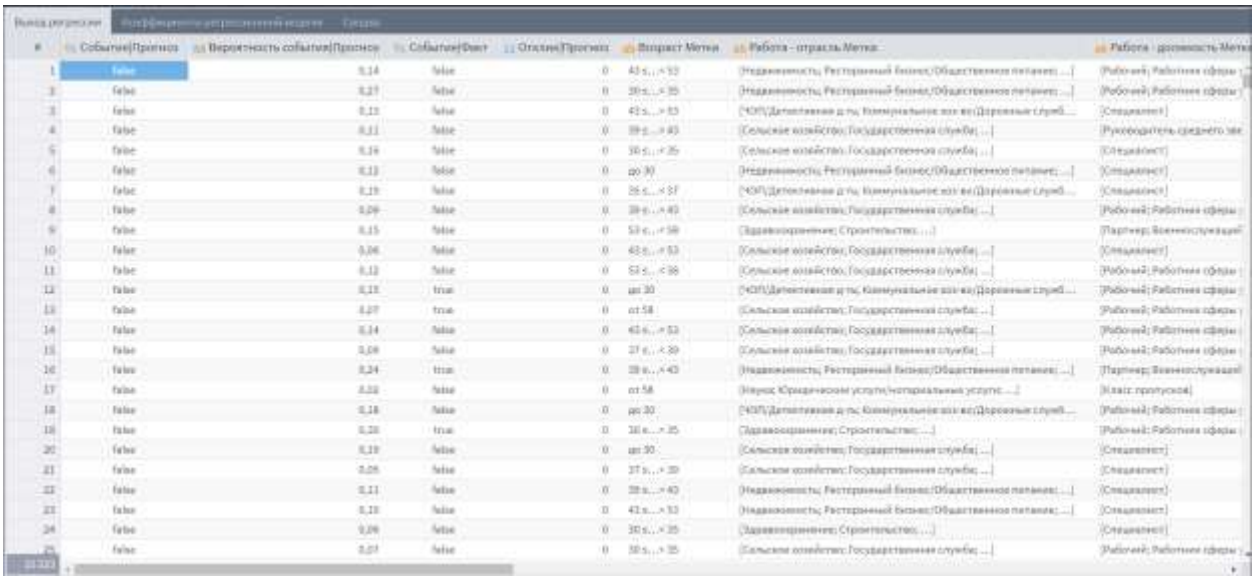

Рисунок 19 – Выход регрессии

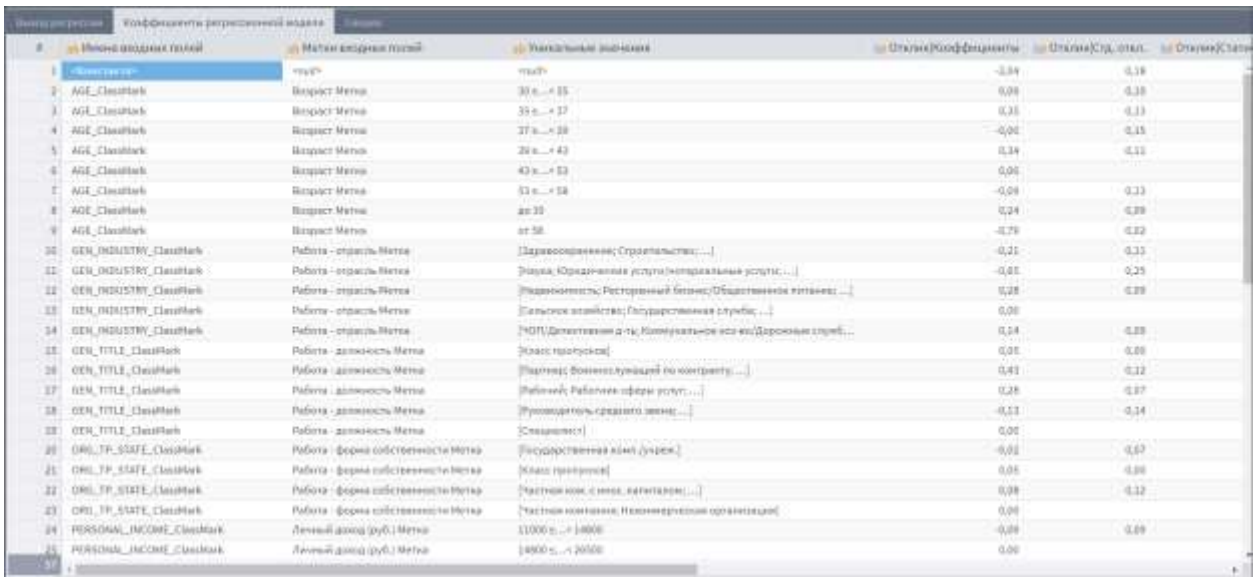

Рисунок 20 – Коэффициенты регрессивной модели

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	15 223
2	12 TotalSelectedSamples	Всего отобранных примеров	15 223
3	12 TrainSamples	Примеров в обучающем множестве	10 656
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,32
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	11,99
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,49
7	9.0 TrainThreshold	Порог отсечения при обучении модели	0,50
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	7 821,02
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	7 311,95
10	9.0 R2	Псевдо-R^2 Макфаддена	0,07
11	9.0 AdjustedR2	Псевдо-R^2 Макфаддена (скорр.)	0,05
12	12 DFE	Число степеней свободы ошибки	10 609
13	12 ModelDF	Число степеней свободы модели	46
14	9.0 Chi2	Хи-квадрат	509,07
15	9.0 AIC	Информационный критерий Акаике	0,70
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,70
17	9.0 BIC	Информационный критерий Байеса	0,73
18	9.0 HQC	Информационный критерий Ханнана-Куинна	0,71
19	9.0 ModelPValue	P-значение модели	2,35e-79
20	12 TestSamples	Примеров в тестовом множестве	4 567
21	9.0 TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,32
22	9.0 TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	11,74
23	9.0 TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,50

Рисунок 21 – Сводка

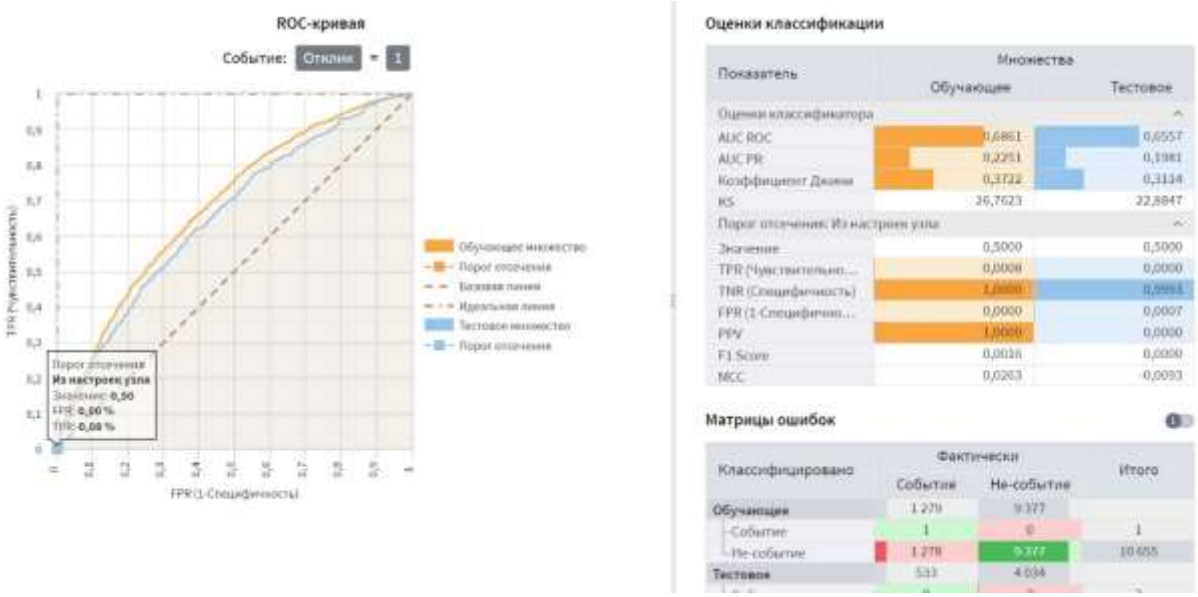

Рисунок 22 – ROC-кривая

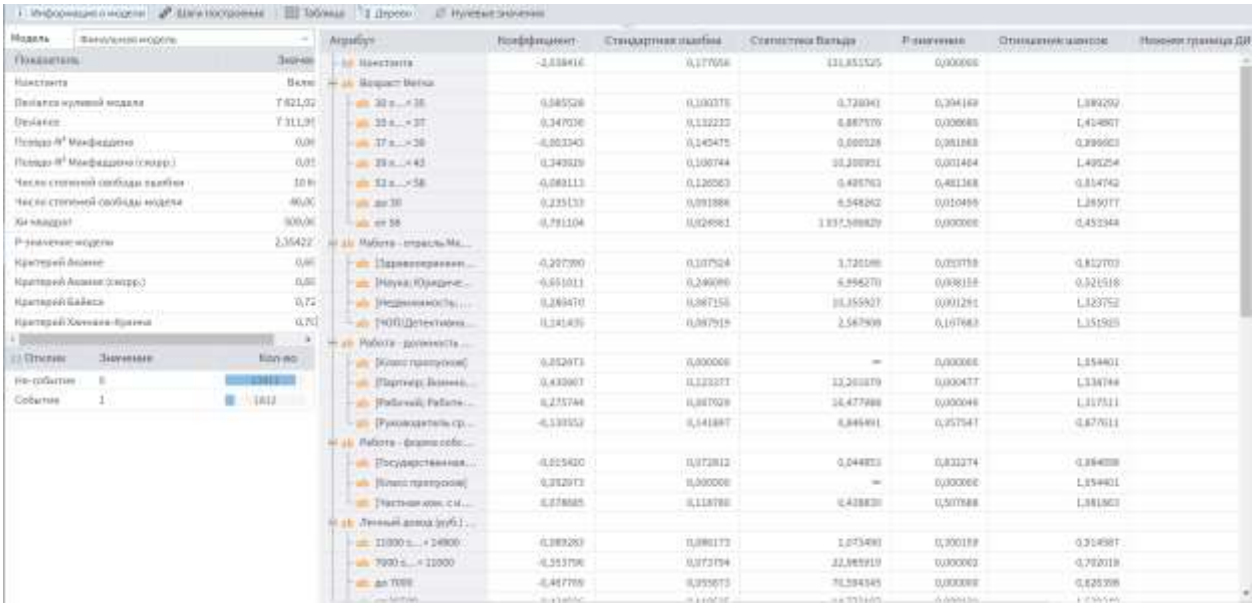

Рисунок 23 – Отчёт по регрессии

По аналогичному сценарию также были построены две логистические регрессии.

Логистическая регрессия по входным параметрам после IV отбора представлена на рисунках 24-28.

Рисунок 24 – Выход регрессии

Рисунок 25 – Коэффициенты регрессивной модели

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	15 223
2	12 TotalSelectedSamples	Всего отобранных примеров	15 223
3	12 TrainSamples	Примеров в обучающем множестве	10 656
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,31
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	11,93
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,48
7	9.0 TrainThreshold	Порог отсечения при обучении модели	0,50
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	7 825,00
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	7 042,24
10	9.0 R2	Псевдо-R^2 Макфаддена	0,10
11	9.0 AdjustedR2	Псевдо-R^2 Макфаддена (скорр.)	0,07
12	12 DFE	Число степеней свободы ошибки	10 550
13	12 ModelDF	Число степеней свободы модели	105
14	9.0 Chi2	Хи-квадрат	782,76
15	9.0 AIC	Информационный критерий Акаике	0,68
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,68
17	9.0 BIC	Информационный критерий Байеса	0,75
18	9.0 HQC	Информационный критерий Ханнана-Куинна	0,71
19	9.0 ModelPValue	P-значение модели	3,61e-104
20	12 TestSamples	Примеров в тестовом множестве	4 567
21	9.0 TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,31
22	9.0 TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	11,60
23	9.0 TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,47

Рисунок 26 – Сводка

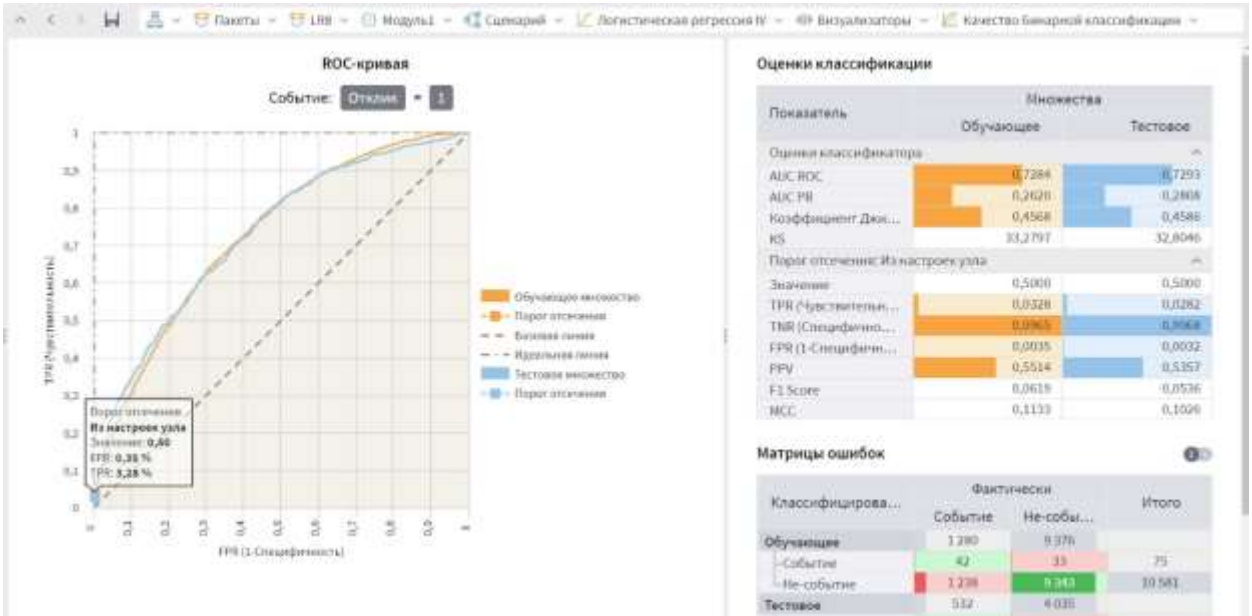

Рисунок 27 – ROC-кривая

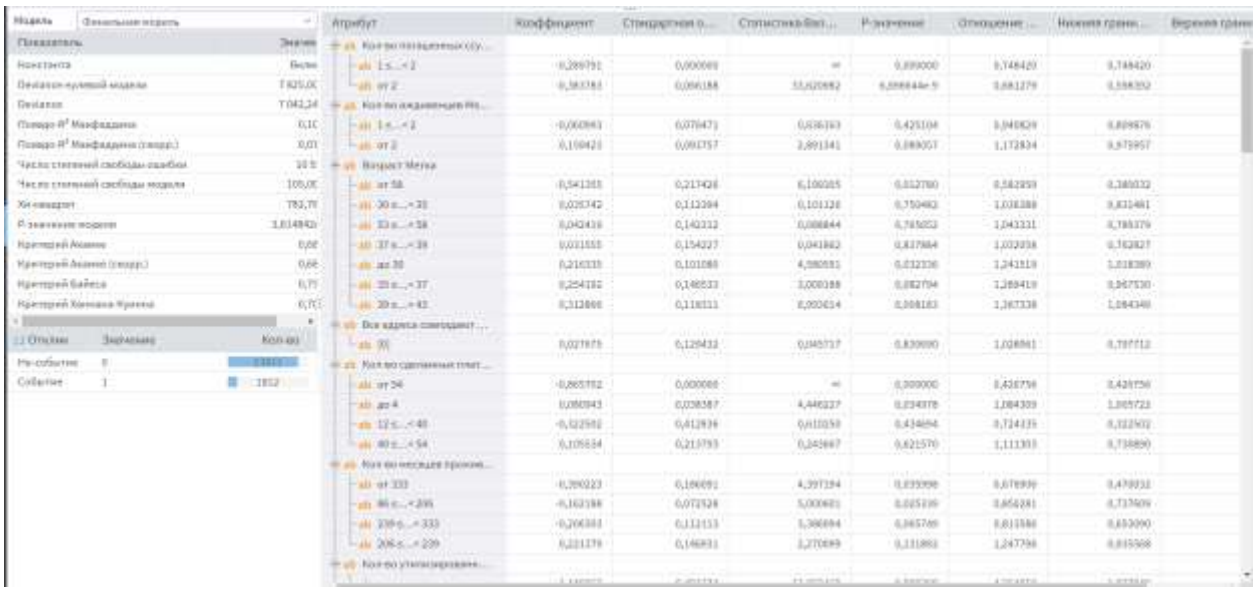

Рисунок 28 – Отчёт по регрессии

Логистическая регрессия построенная по всем параметрам представлена на рисунках 29-33.

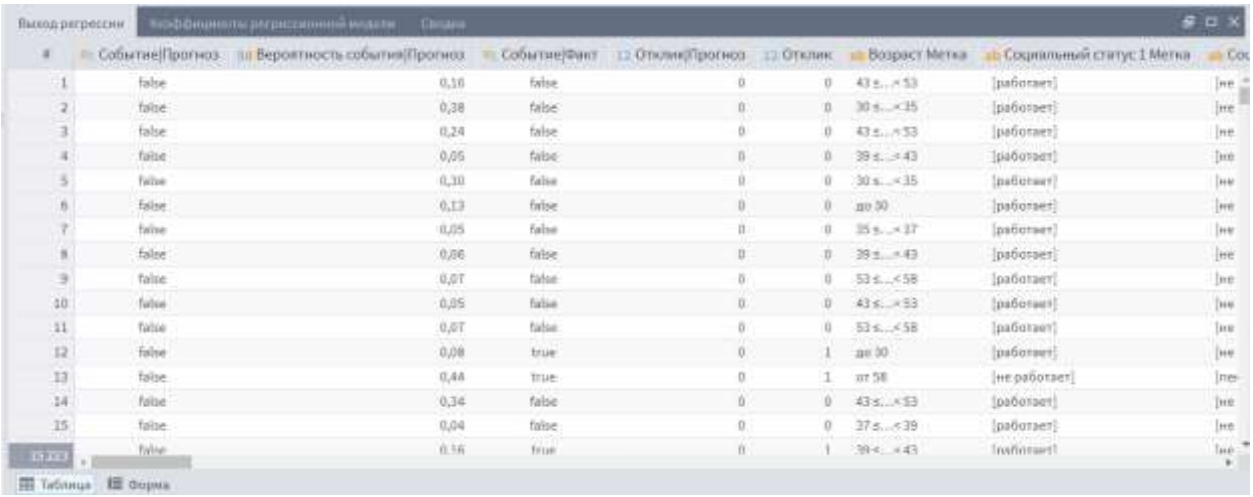

#	Событие|Прогноз	Вероятность события|Прогноз	Событие|Факт	Отклик|Прогноз	Отклик	Возраст Метка	Социальный статус 1 Метка	Соц
1	false	0,16	false	0	0	43 ≤...< 53	[работает]	[не
2	false	0,38	false	0	0	30 ≤...< 35	[работает]	[не
3	false	0,24	false	0	0	43 ≤...< 53	[работает]	[не
4	false	0,05	false	0	0	39 ≤...< 43	[работает]	[не
5	false	0,10	false	0	0	30 ≤...< 35	[работает]	[не
6	false	0,13	false	0	0	до 30	[работает]	[не
7	false	0,05	false	0	0	35 ≤...< 37	[работает]	[не
8	false	0,06	false	0	0	39 ≤...< 43	[работает]	[не
9	false	0,07	false	0	0	53 ≤...< 58	[работает]	[не
10	false	0,05	false	0	0	43 ≤...< 53	[работает]	[не
11	false	0,07	false	0	0	53 ≤...< 58	[работает]	[не
12	false	0,08	true	0	1	до 30	[работает]	[не
13	false	0,44	true	0	1	от 58	[не работает]	[не
14	false	0,34	false	0	0	43 ≤...< 53	[работает]	[не
15	false	0,04	false	0	0	37 ≤...< 39	[работает]	[не
15 223	false	0,16	true	0	1	39 ≤...< 43	[работает]	[не

Рисунок 29 – Выход регрессии

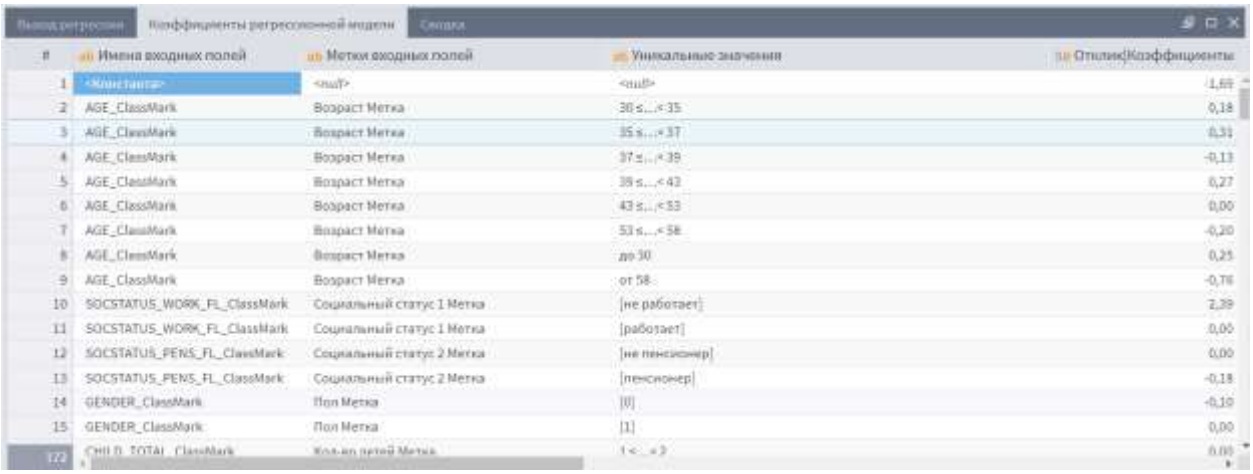

#	Имена входных полей	Метки входных полей	Уникальные значения	Отклик|Коэффициенты
1	<Константа>	<null>	<null>	-1,69
2	AGE_ClassMark	Возраст Метка	30 ≤...< 35	0,18
3	AGE_ClassMark	Возраст Метка	35 ≤...< 37	0,31
4	AGE_ClassMark	Возраст Метка	37 ≤...< 39	-0,13
5	AGE_ClassMark	Возраст Метка	39 ≤...< 43	0,27
6	AGE_ClassMark	Возраст Метка	43 ≤...< 53	0,00
7	AGE_ClassMark	Возраст Метка	53 ≤...< 58	-0,20
8	AGE_ClassMark	Возраст Метка	до 30	0,25
9	AGE_ClassMark	Возраст Метка	от 58	-0,76
10	SOCSTATUS_WORK_FL_ClassMark	Социальный статус 1 Метка	[не работает]	2,39
11	SOCSTATUS_WORK_FL_ClassMark	Социальный статус 1 Метка	[работает]	0,00
12	SOCSTATUS_PENS_FL_ClassMark	Социальный статус 2 Метка	[не пенсионер]	0,00
13	SOCSTATUS_PENS_FL_ClassMark	Социальный статус 2 Метка	[пенсионер]	-0,18
14	GENDER_ClassMark	Пол Метка	[0]	-0,10
15	GENDER_ClassMark	Пол Метка	[1]	0,00
122	CHILD_TOTAL_ClassMark	Кол-во детей Метка	1 < ...< 2	0,00

Рисунок 30 – Коэффициенты регрессивной модели

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	15 223
2	12 TotalSelectedSamples	Всего отобранных примеров	15 223
3	12 TrainSamples	Примеров в обучающем множестве	10 656
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,31
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	11,64
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,46
7	9.0 TrainThreshold	Порог отсечения при обучении модели	0,50
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	7 708,76
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	6 791,17
10	9.0 R2	Псевдо-R^2 Макфаддена	0,12
11	9.0 AdjustedR2	Псевдо-R^2 Макфаддена (скорр.)	0,09
12	12 DFE	Число степеней свободы ошибки	10 529
13	12 ModelDF	Число степеней свободы модели	126
14	9.0 Chi2	Хи-квадрат	917,59
15	9.0 AIC	Информационный критерий Акаике	0,66
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,66
17	9.0 BIC	Информационный критерий Байеса	0,75

Рисунок 31 – Сводка

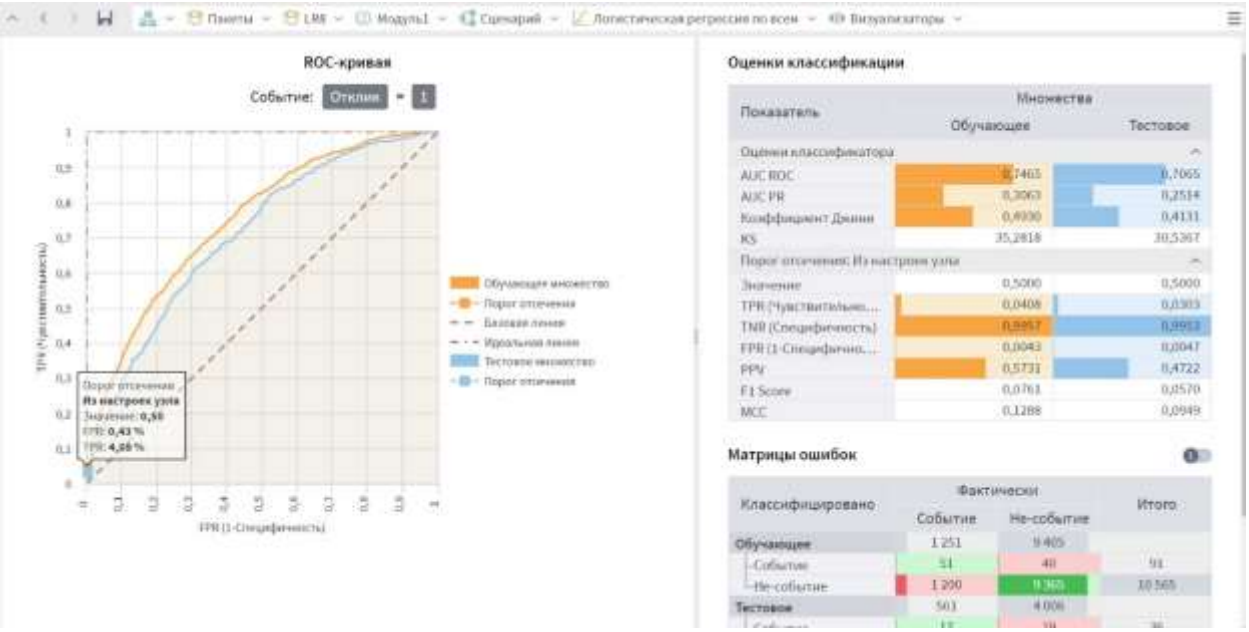

Рисунок 32 – ROC-кривая

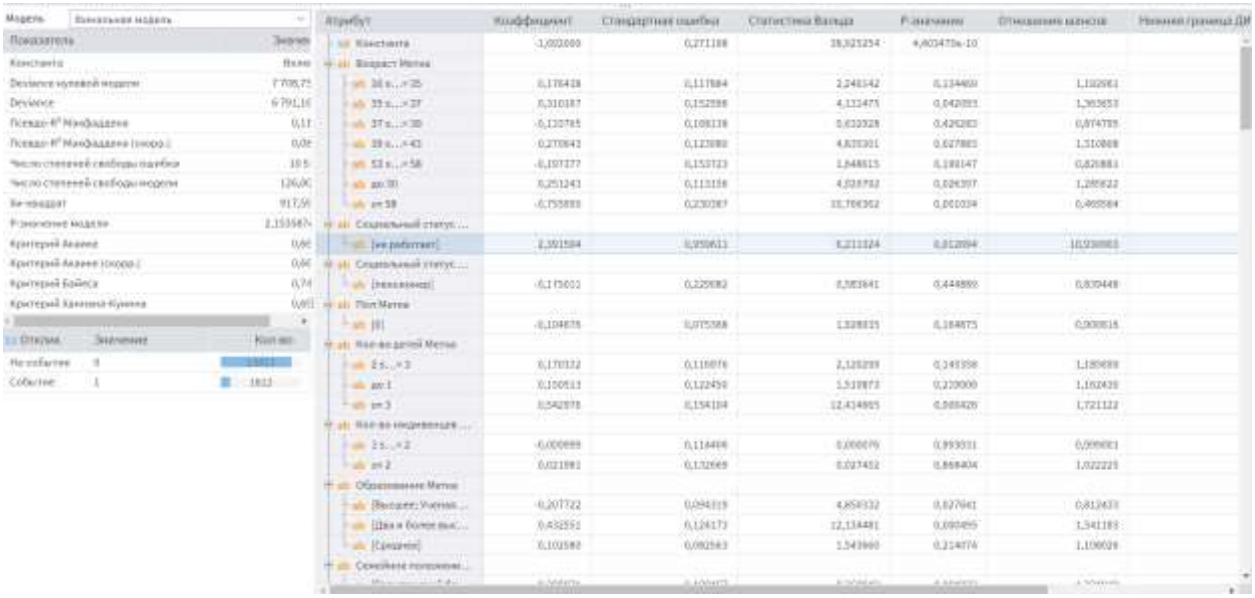

Рисунок 33 – Отчёт по регрессии

Можно заметить, что при уменьшении входных параметров качество регрессии снижается. Это происходит из-за того, что обрезается довольно большое количество малозначимых параметров, которые в сумме дают большую информационную значимость.

Общая значимость была посчитана при помощи визуализатора Куб в компоненте Конечные классы (Рисунки 34, 35,36,37).

	Информ...
> Низкая	1,15
> Отсутствует	0,13
> Средняя	1,32
Итого:	2,59

Рисунок 34 – Визуализатор Куб

		Информ...
Низкая	Все адреса...	0,02
	Кол-во иж...	0,02
	Кол-во мес...	0,06
	Кол-во пог...	0,05
	Кол-во пр...	0,05
	Кол-во сде...	0,04
	Кол-во ути...	0,04
	Максимал...	0,07
	Наличие р...	0,10
	Номер мак...	0,05
	Первонач. ...	0,06
	Последни...	0,02
	Работа - н...	0,10
	Работа - О...	0,09
	Регион РФ	0,05
	Семейный ...	0,03
	Социальн...	0,09
	Социальн...	0,09

Рисунок 35 – Визуализатор Куб низкие значения

		Информ...
Низкая		1,15
Отсутствует	Авто росси...	0,00
	Адрес рег...	0,02
	Адрес рег...	0,02
	Адрес фак...	0,02
	Гараж	0,00
	Загородн...	0,00
	Земельны...	0,00
	Квартира ...	0,00
	Кол-во детей	0,00
	Кол-во ссу...	0,01
	Коттедж	0,00
	Наличие т...	0,00
	Наличие т...	0,01
	Обл. регис...	0,00
	Образова...	0,02
	Пол	0,01
	Семейное ...	0,01

Рисунок 36 – Визуализатор Куб отсутствующие значения

> Низкая		1,15
> Отсутствует		0,13
∨ Средняя	Возраст	0,16
	Личный до…	0,11
	Область р…	0,12
	Область т…	0,11
	Область ф…	0,13
	Почтовый …	0,13
	Работа - д…	0,12
	Работа - от…	0,16
	Работа - ф…	0,12
	Стаж рабо…	0,18
	Итого:	1,32
Итого:		2,59

Рисунок 37 – Визуализатор Куб средние значения

Из Визуализатора Куба можно сделать следующий вывод, что выборку входных параметров стоит осуществлять аккуратно так как например при построении сценария для средних и более значимостью, суммарная значимость критически мала, она уменьшилась на 50 процентов.

Вывод

В ходе лабораторной работы была создана модель биннинга для набора данных otp_train.lgd, были настроены и добавлены компоненты Конечные классы и IV-отбор. После был построен сценарий позволяющий отделить значащие столбцы и использовать их для дальнейшего анализа, например, в логистической регрессии, как и было представлено в лабораторной работе.

Компонент Конечные классы позволил разбить условно непрерывные данные на бины, сокращая количество информации, а также позволил оценить значимость каждого из входных значений для дальнейшей подготовки данных, согласно нашей задаче.