ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ _____

ПРЕПОДАВАТЕЛЬ

канд. техн. наук , доцент		Н.В. Богословская
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №4

Кластеризация.

по курсу: Большие данные

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. № 4329		Д.С. Шаповалова
	подпись, дата	инициалы, фамилия

Санкт-Петербург 2026

1. Цель работы:

Освоить практические навыки построения и отбора признаков при подготовке данных для задач машинного обучения, используя как визуальные (low-code) инструменты платформы Loginom, так и узел Python для написания исполняемого кода.

2. Задание:

1. Для двух наборов: Высшее образование.xls, Здравоохранение.xls реализуйте кластеризацию алгоритмами EM, k-mean, g-means.
2. Для набора transactions_diy.lgd реализуйте кластеризацию транзакций [4, 5].
3. Выполните оценку качества всех полученных моделей.
4. Предложите интерпретацию полученных кластеров.
5. Разработайте визуальные отчеты пользователю для изучения полученных кластеров.

3. Ход работы

Для набора Высшее образование была реализована кластеризация алгоритмом k-means (количество кластеров известно) и g-means (количество кластеров неизвестно).

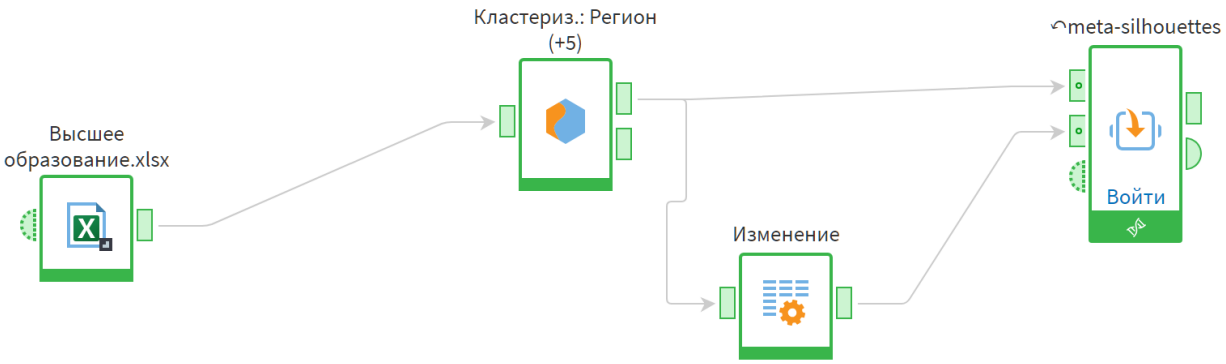

Рисунок 1.1 – Кластеризация

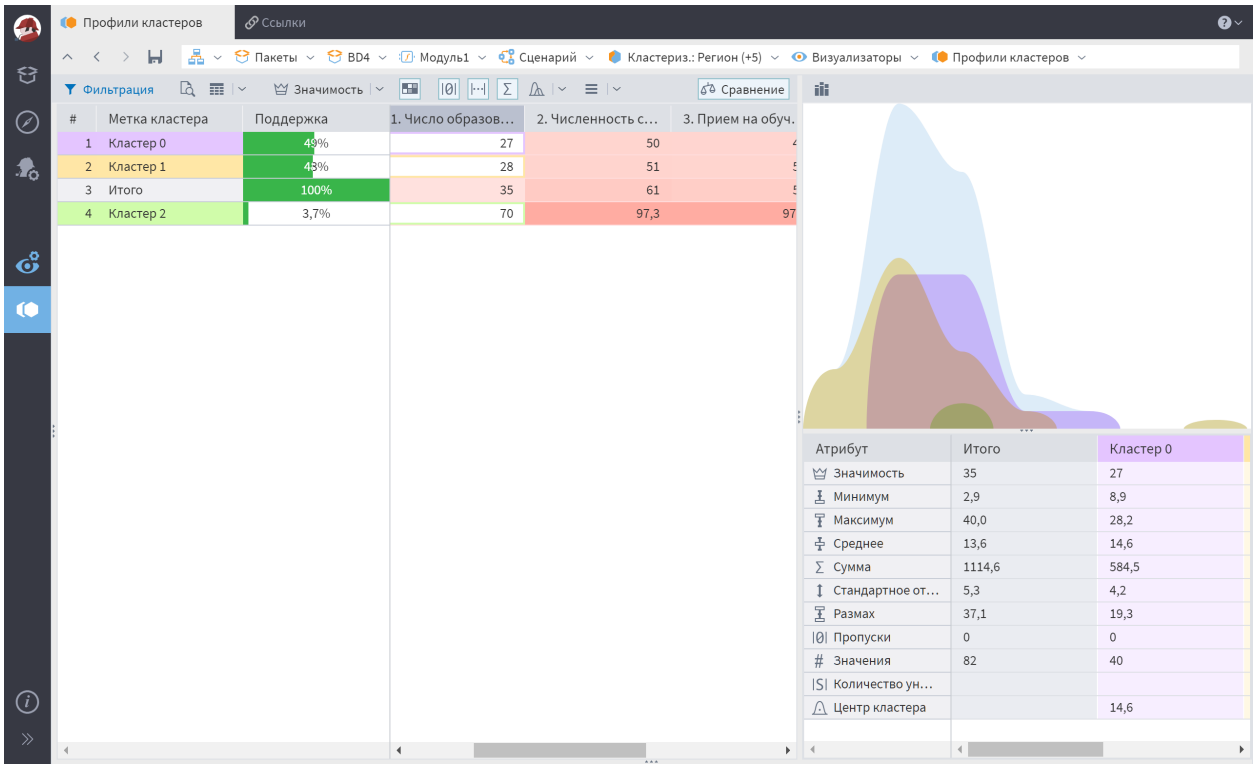

Рисунок 1.2 – Профили кластеров Высшего образования

Проверка качества кластеризации была выполнена через производный компонент meta-silhouettes.

meta-silhouettes • Быстрый просмотр

Индексы силуэтов | Индекс силуэта

#	12 Номер строки	9.0 Индекс силуэта	ab Кластер	9.0 Cluster	9.0 Distance	9.0 _1__CHislo_obrazovatelnykh_organizatsiy__vysshego_obraz...
1	10	0,76	2	2,56	-0,84	0,4
2	20	0,72	2	2,56	-0,41	0,6
3	30	0,70	2	2,56	-0,52	0,2
4	40	0,41	1	0,80	-0,45	-0,9
5	50	0,40	1	0,80	0,19	-1,5
6	60	0,40	1	0,80	-0,81	-0,5
7	70	0,40	1	0,80	-0,62	0,1
8	80	0,39	1	0,80	0,08	0,4
9	90	0,38	1	0,80	0,21	-0,6
10	100	0,38	1	0,80	-0,84	-0,3
11	110	0,37	1	0,80	0,11	-0,7
12	120	0,37	1	0,80	-0,23	-1,3
13	130	0,36	1	0,80	-0,35	-0,8
14	140	0,36	1	0,80	-0,67	-0,2
15	150	0,35	1	0,80	-0,76	-0,0
16	160	0,35	1	0,80	-0,39	-0,1
17	170	0,35	1	0,80	-0,64	-0,7
18	180	0,34	1	0,80	-0,09	0,9
19	190	0,33	1	0,80	-0,67	0,2
20	200	0,33	1	0,80	-0,79	-0,0
21	210	0,33	1	0,80	-0,71	-0,5
22	220	0,32	1	0,80	0,36	0,8

82

Рисунок 1.3 – Проверка качества кластеризации

Также было сформировано графическое построение кластерных силуэтов для проведения оценки качества кластеризации. Оценка показала среднее качество.

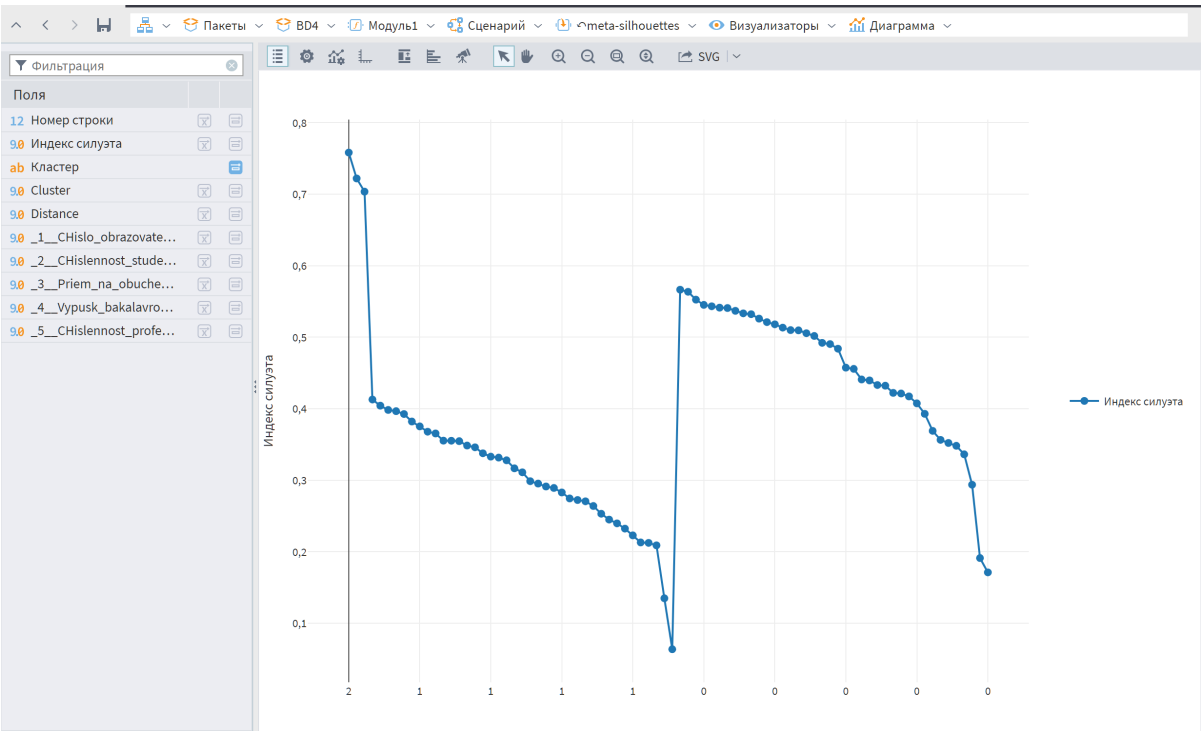

Рисунок 1.4 – Кластерные силуэты

meta-silhouettes • Быстрый просмотр

Индексы силуэтов | Индекс силуэта

№	Имя	Метка	Значение
1	SilhouetteCoefficient	Индекс силуэта	0,39
2	Quality	Качество кластеризации	Среднее

Рисунок 1.5 – Индекс силуэта

По результатам кластеризации были выделены следующие кластеры:

1) Области с высокообразованным населением
2) Области с средним количеством образованного населения
3) Области с низким уровнем образования

Далее была применена более чувствительная к входным параметрам EM кластеризация для набора данных Здравоохранение.

Номер кластера ASC • Быстрый просмотр

Выходной набор данных

#	12 Номер кластера	9.0 Вероятность принадлежности	ab Регион	9.0 Мощность амбулаторно-поликлинических у
47	0	0,86	Алтайский край	
48	0	0,95	Забайкальский край	
49	0	0,86	Красноярский край	
50	0	0,79	Иркутская область	
51	0	0,92	Кемеровская область	
52	0	0,98	Новосибирская область	
53	0	0,93	Омская область	
54	0	0,98	Томская область	
55	0	0,98	Приморский край	
56	0	0,95	Амурская область	
57	1	0,82	Костромская область	
58	1	0,99	Московская область	
59	1	1,00	г. Москва	
60	1	1,00	Республика Коми	
61	1	0,99	Архангельская область	
62	1	1,00	Ленинградская область	
63	1	0,99	Мурманская область	
64	1	1,00	г. Санкт-Петербург	
65	1	0,78	Республика Крым	
66	1	0,83	Краснодарский край	
67	1	1,00	г. Севастополь	
68	1	1,00	Республика Дагестан	
82				

Таблица Форма

Рисунок 2 – Результат EM кластеризации

Также использовалась кластеризация транзакций с использованием алгоритма CLOPE.

CLOPE: Клиент, Товар • Быстрый просмотр

Разбиение на кластеры | Параметры кластеров

#	12 Номер кластера	ab Клиент
41 061	1	client21052
41 062	0	client21234
41 063	1	client42331
41 064	1	client39531
41 065	1	client3179
41 066	8	client5197
41 067	1	client8267
41 068	1	client31704
41 069	1	client2043
41 070	1	client9152
41 071	1	client7075
41 072	1	client37166
41 073	1	client13307
41 074	1	client36917
41 075	1	client23329
41 076	1	client29504
41 077	1	client3439
41 078	1	client40160
41 079	1	client16966
41 080	1	client10356
41 081	1	client42196
41 082	1	client13573
42 746	1	client37939

Рисунок 3 – Результат кластеризации транзакций

ВЫВОД

В ходе работы освоены алгоритмы кластеризации (k-means, g-means, EM, CLOPE) и практические правила их применения: подготовка данных, выбор метрик, интерпретация результатов.

Метод «локтя» позволил обоснованно подобрать количество кластеров; компонент meta-silhouettes подтвердил удовлетворительное качество моделей.

Сравнение low-code и Python-подходов показало: визуальные компоненты Loginom обеспечивают скорость и наглядность, а скрипты дают гибкость в кастомизации метрик и алгоритмов.

Главный итог: кластеризация полезна только при содержательной интерпретации – без присвоения кластерам осмысленных названий («Молодёжь», «VIP-клиенты» и т.д.) результаты не имеют практической ценности.